



# 支持向量机 SVM


## 一. 线性模型



线性可分训练集

非线性可分

可以证明: 如果 存在一条直线 可以分开两个样本集, 则有 无数条直线 可以将其分开



最大化间隔

$d$ : 间隔

支持向量: 平行线插到的向量 support Vector

定义:

① 训练数据及标签

$(x_1, y_1) (x_2, y_2) \dots (x_n, y_n)$

向量  $x_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{in} \end{bmatrix}$  标签  $y_i = +1/-1$

② 线性模型:  $(w, b)$   $w^T x + b = 0$  超平面

向量  $w = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix}$  常数

③ 一个训练集 线性可分 是指:

$\{(x_i, y_i)\}_{i=1 \sim N}$   $\exists (w, b)$  使  $\forall i = 1 \sim N$  有:

① 若  $y_i = +1$ , 则  $w^T x_i + b \geq 0$

② 若  $y_i = -1$ , 则  $w^T x_i + b < 0$

即  $y_i (w^T x_i + b) \geq 0$

SVM 优化问题: (凸优化)

$$\min \quad \frac{1}{2} \|w\|^2$$

$$\text{s.t.} \quad y_i [w^T x_i + b] \geq 1, \quad i = 1 \sim N$$

事实1:  $w^T x + b = 0$  与  $a w^T x + a b = 0$  是同一个平面.

$$a \in \mathbb{R}^+$$

事实2: 点到平面距离 平面:  $w_1 x + w_2 y + b = 0$

点:  $(x_0, y_0)$

$$d = \frac{|w_1 x_0 + w_2 y_0 + b|}{\sqrt{w_1^2 + w_2^2}}$$

$$d = \frac{|w^T x_0 + b|}{\|w\|}$$

可以用  $a$  缩放  $(w, b) \rightarrow (aw, ab)$

使在支持向量  $x_0$  上, 有  $|w^T x_0 + b| = 1$

此时支持向量与平面距离  $d = \frac{1}{\|w\|}$

## 二. 非线性模型 事先没学过, 正则项


① 最小化:  $\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$  松弛变量

s.t. : ①  $y_i [w^T \varphi(x_i) + b] \geq 1 - \xi_i \quad i=1 \sim N$

②  $\xi_i \geq 0$

② 高维映射  $\varphi(x)$

$x \xrightarrow{\varphi} \varphi(x)$   
二维      高维



异或问题

$x_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \in C_1 \quad x_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \in C_1$

$x_3 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \in C_2 \quad x_4 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \in C_2$

$\varphi(x)_x = \begin{bmatrix} a \\ b \end{bmatrix} \xrightarrow{\varphi} \varphi(x) = \begin{bmatrix} a^2 \\ b^2 \\ a \\ b \\ ab \end{bmatrix}$

$\varphi(x_1) = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \quad \varphi(x_2) = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \in C_1$

$\varphi(x_3) = \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} \quad \varphi(x_4) = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 1 \\ 0 \end{bmatrix} \in C_2$

$w = \begin{bmatrix} -1 \\ -1 \\ -1 \\ -1 \\ 6 \end{bmatrix} \quad b = 1$

维度越高, 被线性分开的概率越大.

$\varphi(x)$  是无限维的.



我们可以不知道无限维映射  $\varphi(x)$  的显示表达，  
我们只要知道一个核函数

一个数  $K(x_1, x_2) = \varphi(x_1)^T \varphi(x_2)$

则 ① 这个优化式仍然可解。

$\varphi(x_1)$  与  $\varphi(x_2)$  两个  
无限维向量的内积

核函数：高斯核  $K(x_1, x_2) = e^{-\frac{\|x_1 - x_2\|^2}{2\sigma^2}}$

多项式核  $K(x_1, x_2) = (x_1^T x_2 + 1)^d$   $\leftarrow$  多项式阶数

$K(x_1, x_2)$  能写成  $\varphi(x_1)^T \varphi(x_2)$  的充要条件：

①  $K(x_1, x_2) = K(x_2, x_1)$  交换性

②  $\forall c_i, x_i (i=1 \sim N)$  有：

$\sum_{i=1}^N \sum_{j=1}^N c_i c_j K(x_i, x_j) \geq 0$  半正定性

优化理论

原问题：

$$\min : f(w)$$

$$\text{s.t.} : g_i(w) \leq 0, i=1 \sim k$$

$$h_i(w) = 0, i=1 \sim m$$

对偶问题:

① 定义:  $L(w, \alpha, \beta) = f(w) + \sum_{i=1}^k \alpha_i g_i(w) + \sum_{i=1}^m \beta_i h_i(w)$   
 $= f(w) + \alpha^T g(w) + \beta^T h(w)$

②  $\max : \theta(\alpha, \beta) = \inf_{\text{所有 } w} \{L(w, \alpha, \beta)\}$   $\alpha, \beta$  确定  
s.t.  $\alpha_i \geq 0 \quad (i=1 \sim k)$

定理: 如果  $w^*$  是原问题的件, 而  $\alpha^*, \beta^*$  是对偶问题的件, 则有  $f(w^*) \geq \theta(\alpha^*, \beta^*)$

证明:  $\theta(\alpha^*, \beta^*) = \inf_{\forall w} \{L(w, \alpha^*, \beta^*)\}$   
 $\leq L(w^*, \alpha^*, \beta^*)$   
 $= f(w^*) + \sum_{i=1}^k \alpha_i^* g_i(w^*) + \sum_{i=1}^m \beta_i^* h_i(w^*)$   
 $\leq f(w^*)$   $\begin{matrix} \geq 0 & \leq 0 & = 0 \\ \# \end{matrix}$

定义:  $G = f(w^*) - \theta(\alpha^*, \beta^*) \geq 0$

$G$  叫做 原问题与对偶问题的间距

对于某些特定的优化问题 可以证明  $G=0$ .

强对偶定理: 若  $f(w)$  是凸函数, 且  $g(w) = Aw + b$   
 $h(w) = cw + d$ , 则此优化问题的原问题与对偶问题间距为 0. 即  $f(w^*) = \theta(\alpha^*, \beta^*)$

对于  $\forall i=1 \sim k$  或者  $\alpha_i^* = 0$  或者  $g_i(w^*) = 0$  KKT 条件

原问题:

$$\min: \frac{1}{2} \|w\|^2 + c \sum_{i=1}^N \epsilon_i$$

$$\text{s.t.}: \textcircled{1} y_i [w^T \phi(x_i) + b] \geq 1 - \epsilon_i$$

$$\textcircled{2} \epsilon_i \geq 0$$

↓

$$\min: \frac{1}{2} \|w\|^2 - c \sum_{i=1}^N \epsilon_i$$

$$\text{s.t.}: \textcircled{1} 1 + \epsilon_i - y_i w^T \phi(x) - y_i b \leq 0$$

$$\textcircled{2} \epsilon_i \leq 0$$

对偶问题:

$$\max: \theta(\alpha, \beta) = \inf_{(w, \epsilon, b)} \left\{ \frac{1}{2} \|w\|^2 - c \sum_{i=1}^N \epsilon_i + \sum_{i=1}^N \beta_i \epsilon_i + \sum_{i=1}^N \alpha_i [1 + \epsilon_i - y_i w^T \phi(x) - y_i b] \right\}$$

$$\text{s.t.}: \alpha_i \geq 0, i=1 \sim N$$

$$\beta_i \geq 0$$

$$\frac{\partial L}{\partial w} = 0 \Rightarrow w - \sum_{i=1}^N \alpha_i y_i \phi(x_i) = 0$$

$$\frac{\partial L}{\partial \epsilon_i} = 0 \Rightarrow -c + \beta_i + \alpha_i = 0$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow -\sum_{i=1}^N \alpha_i y_i = 0$$

代  $\lambda$   $\theta(\alpha, \beta)$



$$\theta(\alpha, \beta) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j k(x_i, x_j)$$

$$\frac{1}{2} \|w\|^2 = \frac{1}{2} w^T w$$

$$= \frac{1}{2} \left( \sum_{i=1}^N \alpha_i y_i \varphi(x_i) \right)^T \left( \sum_{j=1}^N \alpha_j y_j \varphi(x_j) \right)$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \underbrace{\varphi(x_i)^T \varphi(x_j)}_{=k(x_i, x_j)}$$

$$- \sum_{i=1}^N \alpha_i y_i w^T \varphi(x_i) = - \sum_{i=1}^N \alpha_i y_i \left( \sum_{j=1}^N \alpha_j y_j \varphi(x_j) \right)^T \varphi(x_i)$$

$$= - \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \underbrace{\varphi(x_j)^T \varphi(x_i)}_{=k(x_i, x_j)}$$

对偶问题:

$$\max : \theta(\alpha, \beta) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j k(x_i, x_j)$$

$$\text{s.t. } ① 0 \leq \alpha_i \leq c$$

$$② \sum_{i=1}^N \alpha_i y_i = 0$$

测试流程:

测试样本  $x$ ,

$$\begin{cases} \text{若 } w^T \varphi(x) + b \geq 0, \text{ 则 } y = +1 \\ \text{若 } w^T \varphi(x) + b < 0, \text{ 则 } y = -1 \end{cases}$$

$$\begin{aligned} w^T \varphi(x) &= \sum_{i=1}^N [\alpha_i y_i \varphi(x_i)]^T \varphi(x) \\ &= \sum_{i=1}^N \alpha_i y_i \varphi(x_i)^T \varphi(x) \\ &= \sum_{i=1}^N \alpha_i y_i k(x_i, x) \end{aligned}$$

KKT条件:  $\forall i=1 \sim N$

① 要么  $\beta_i = 0$ , 要么  $\epsilon_i = 0$

② 要么  $\alpha_i = 0$ , 要么  $1 + \epsilon_i - y_i w^T \varphi(x_i) - y_i b = 0$

取一个  $0 < \alpha_i < C \Rightarrow \beta_i = C - \alpha_i > 0$

此时  $\beta_i \neq 0 \Rightarrow \epsilon_i = 0$

$\alpha_i \neq 0 \Rightarrow 1 - y_i w^T \varphi(x_i) - y_i b = 0$

$$b = \frac{1 - y_i w^T \varphi(x_i)}{y_i} = \frac{1 - y_i \sum_{i=1}^N \alpha_i y_i K(x_i, x_i)}{y_i}$$

SVM流程

1. 训练流程, 求  $\alpha$

$$\max \theta(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

s.t. ①  $0 \leq \alpha_i \leq C$

②  $\sum_{i=1}^N \alpha_i y_i = 0$

求  $b$ , 完成训练, 见上

2. 测试流程, 考察测试数据  $x$ , 预测类别  $y$

