



智能优化算法

第2章 数学基础知识



2.1 数字图像数据



2.2 导数，梯度，散度

2.3 范数

2.1 数字图像数据



- 数字图片，通过像机等拍摄获取，
- 数据类型: jpg, png, gif....
- 规则的格子构成的二维数据 x, y



2.1.1 数字图像表示



$$f(x, y) = \begin{bmatrix} f(0,0) & f(0,1) & \cdots & f(0, N-1) \\ f(1,0) & f(1,1) & \cdots & f(1, N-1) \\ \vdots & \vdots & & \vdots \\ f(M-1,0) & f(M-1,1) & \cdots & f(M-1, N-1) \end{bmatrix}$$

这个表达式的右侧定义了一幅数字图像。矩阵中的每个元素称为图像像素。

1. 大小为 $M*N$ 的图像：二维函数 $f(x, y)$,
2. (x, y) 为坐标, $f(x, y)$ 为坐标值, 也即像素值
3. 灰度图: $M*N$, $f(i, j) = c$
彩色图: $M*N*3$, $f(i, j) = (r, g, b)$
4. 其中, 像素值的大小范围为 $[0, 255]$ 的整数值



彩色图、灰度图、二值图



$[r,g,b]--[0,255]$


$[c]--[0,255]$

0,1



下一页 上一页

2.1.2 像素坐标系:



左图为, $M*N$ 图像的坐标系

1、坐标原点位于左上角

2、数据先沿x轴增加

3、然后再沿y轴增加

4、坐标轴为整数

5、**matlab**中原点为(1,1)

2.1.3 像素间的关系与距离




- 像素 $p(m,n)$ 的相邻像素

4邻域 $N_4(p)$: $(m+1, n)$, $(m-1, n)$, $(m, n+1)$, $(m, n-1)$

对角邻域 $N_D(p)$: $(m+1, n+1)$, $(m+1, n-1)$, $(m-1, n+1)$, $(m-1, n-1)$

8邻域 $N_8(p)$: $N_4(p) + N_D(p)$



像素间距离的度量



像素 $P(x, y)$, $Q(s, t)$ 间的距离

- 欧氏距离:

$$D_e(p, q) = \left[(x - s)^2 + (y - t)^2 \right]^{\frac{1}{2}}$$

- D_4 距离（城市街区距离）:

$$D_4(p, q) = |x - s| + |y - t|$$

- D_8 距离（棋盘距离）:

$$D_8(p, q) = \max(|x - s|, |y - t|)$$

2.1.4 数字图像的 matlab命令



- 读取图像: `I = imread('scene.jpg');`
- 显示图像: `imshow(I);`
- 获取图像的大小: `[m,n,r] = size(I);`
- 彩图转灰度图: `gray_I = rgb2gray(I);`
- 图像数据类型转换: `double(I);`
- RGB转HSV: `I_h=rgb2hsv(I);`
- 彩色图转二值图像:
`thresh_I = graythresh(I);`
`im2_I = im2bw(I, thresh_I);`

2.2 图像数据的微分算子



标量定义：只有大小，没有方向，常数

向量定义：有大小，也有方向

n 维向量写成行的形式，称为**行向量**，记为

$$\alpha^T = (a_1, a_2, \dots, a_n),$$

写成列的形式，称为**列向量**，记为

$$\alpha = \begin{bmatrix} a_1 \\ a_2 \\ \dots \\ a_n \end{bmatrix}.$$

2.2.1 向量内积



向量内积：常数

$$\vec{i} = (1, 0, 0) \quad \vec{j} = (0, 1, 0) \quad \vec{k} = (0, 0, 1)$$

$$\mathbf{a} = (x_1, y_1, z_1) = x_1 \vec{i} + y_1 \vec{j} + z_1 \vec{k},$$

$$\mathbf{b} = (x_2, y_2, z_2) = x_2 \vec{i} + y_2 \vec{j} + z_2 \vec{k}$$

$$\langle \mathbf{a}, \mathbf{b} \rangle = \mathbf{a} \cdot \mathbf{b} = x_1 y_1 + x_2 y_2 + x_3 y_3$$

对任意的 $x, y \in \mathbf{R}^n$,

$$\langle x, y \rangle = x^T y = \sum_{i=1}^n x_i y_i.$$

投影


- 内积：二维向量 A, B 内积定义

$$A \cdot B = |A| |B| \cos \theta$$

- 投影：假设 B 为单位向量， $|B|=1$,

$$A \cdot B = |A| \cos \theta$$

- A 与 B 的**内积值**等于 A 向 B 所在直线投影的矢量长度



坐标系与向量




- 右图中二维坐标系的基: $\vec{e}_1 = (1,0), \vec{e}_2 = (0,1)$
- 向量 $(3,2)$ 完整表示为:

$$(3,2) = 3\vec{e}_1 + 2\vec{e}_2$$

- 在x轴方向的投影为3, 在y轴方向的投影为2
- 上式又可写为

$$(3,2) = \langle (3,2), \vec{e}_1 \rangle \vec{e}_1 + \langle (3,2), \vec{e}_2 \rangle \vec{e}_2$$

因此, 对于 n 维向量 $\vec{a} = (a_1, a_2, \dots, a_n)$,



有

$$\vec{a} = \sum_{i=1}^n \langle \vec{a}, \vec{e}_i \rangle \vec{e}_i$$

2.2.2 矩阵



定义1 由 $m \times n$ 个数 $a_{ij} (i=1, 2, \dots, m; j=1, 2, \dots, n)$ 排成一个 m 行 n 列的矩形表称为一个 $m \times n$ 矩阵, 记作

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

其中 a_{ij} 称为矩阵的第 i 行第 j 列的元素.

一般情况下, 我们用大写字母 A, B, C 等表示矩阵.

$m \times n$ 矩阵 A 简记为 $A=(a_{ij})_{m \times n}$ 或记作 $A_{m \times n}$.

稀疏矩阵(Sparse Matrix)

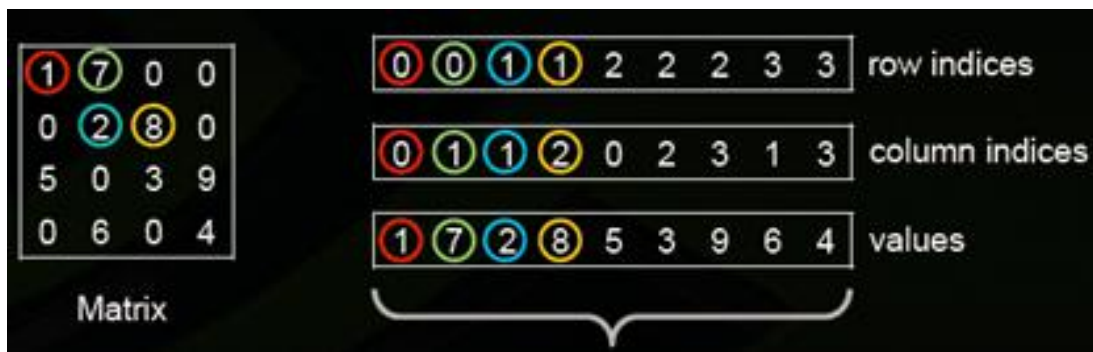


定义： 矩阵中非零元素的个数远远小于矩阵元素的总数

$$M = \begin{bmatrix} 2 & 0 & 0 & 0 & 6 & 0 & 0 & 7 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 8 & 0 & 0 \\ 0 & 0 & 0 & 5 & 0 & 0 & 0 & 0 \\ 0 & 9 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

稀疏矩阵示意图

存储方式： 用三元组来表示，分别是（行号，列号，数值）



```
a = [1 1 1 2 3 3 4 5 6];  
b = [1 5 8 3 3 7 6 4 2];  
v = [2 6 7 1 2 3 8 5 9];  
A = sparse(a, b, v);
```

矩阵内积



1. 矩阵 A, B 内积定义：对应元素相乘求和

$$A \bullet B = \sum_{ij} a_{ij} b_{ij}$$

2. 矩阵A的迹(trace)：A的主对角线（从左上方至右下方的对角线）上各个元素的总和：

$$\text{tr}A = \sum_{i=1}^n A_{ii}.$$

矩阵分解



- 对称特征值分解，矩阵为方阵

假设 $A \in \mathbf{S}^n$ ，即 A 是实对称 $n \times n$ 矩阵。那么 A 可以因式分解为

$$A = Q\Lambda Q^T,$$

其中 $Q \in \mathbf{R}^{n \times n}$ 是正交矩阵，即满足 $Q^T Q = I$ ，

而 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ $\because \lambda_i$ 是 A 的特征值

矩阵 $A \in \mathbf{R}^{n \times n}$ 被称为正交矩阵的条件是

$$A^T A = I, \text{ 即 } A^{-1} = A^T$$



- 奇异值分解：矩阵为任意阶矩阵

假设 $A \in \mathbf{R}^{m \times n}$, $\text{rank } A = r$ 。那么 A 可以因式分解为

$$A = U \Sigma V^T,$$

其中 $U \in \mathbf{R}^{m \times r}$ 满足 $U^T U = I$, $V \in \mathbf{R}^{n \times r}$ 满足 $V^T V = I$,

$\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$ σ_i 则称为奇异值。

求 U, V, Σ 分别是什么？

如何求出分解后的三个矩阵? U, V, Σ



□ 构造对称方阵: $A^T A$

□ 对其进行特征分解:

$$A^T A v_i = \lambda_i v_i \quad \text{记 } V' = [v_1 \cdots v_n]$$

□ 同样构造对称方阵:

$$A A^T$$

□ 对其进行特征分解:

$$A A^T u_i = \lambda_i u_i \quad \text{记 } U' = [u_1 \cdots u_m]$$

注:
矩阵与其转置矩阵的特征值相同

如何求出分解后的三个矩阵? U, V, Σ



- 需要证明A分解的 U, V 为以上定义的 U, V

$$\because A = U\Sigma V^T,$$

$$\therefore A^T = V\Sigma^T U^T \Rightarrow A^T A = V\Sigma^2 V^T$$

$\therefore A^T A$ 的特征向量组 V 即是SVD中的 V 矩阵

同理 AA^T 的特征向量组 U 即是SVD中的 U 矩阵

$$\Sigma: \sigma_i = \sqrt{\lambda_i}$$

注:

矩阵与其转置矩阵的特征值相同



奇异值分解可以写成

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T,$$

其中 $u_i \in \mathbf{R}^m$ 是左奇异向量, $v_i \in \mathbf{R}^n$ 是右奇异向量。

例： 求矩阵的SVD分解：



$$\mathbf{A} = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix}$$

首先求出 $\mathbf{A}^T \mathbf{A}$ 和 $\mathbf{A} \mathbf{A}^T$

$$\mathbf{A}^T \mathbf{A} = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

$$\mathbf{A} \mathbf{A}^T = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 1 \end{pmatrix}$$

进而求出 $A^T A$ 的特征值和特征向量:

$$\lambda_1 = 3; v_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}; \lambda_2 = 1; v_2 = \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

接着求 AA^T 的特征值和特征向量:

$$\lambda_1 = 3; u_1 = \begin{pmatrix} 1/\sqrt{6} \\ 2/\sqrt{6} \\ 1/\sqrt{6} \end{pmatrix}; \lambda_2 = 1; u_2 = \begin{pmatrix} 1/\sqrt{2} \\ 0 \\ -1/\sqrt{2} \end{pmatrix}; \lambda_3 = 0; u_3 = \begin{pmatrix} 1/\sqrt{3} \\ -1/\sqrt{3} \\ 1/\sqrt{3} \end{pmatrix}$$

用 $\sigma_i = \sqrt{\lambda_i}$ 直接求出奇异值为 $\sqrt{3}$ 和1.


$$A = U\Sigma V^T = \begin{pmatrix} 1/\sqrt{6} & 1/\sqrt{2} & 1/\sqrt{3} \\ 2/\sqrt{6} & 0 & -1/\sqrt{3} \\ 1/\sqrt{6} & -1/\sqrt{2} & 1/\sqrt{3} \end{pmatrix} \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

SVD的性质：矩阵的秩为k时



- 矩阵的奇异值个数很少，可如下逼近：

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V_{n \times n}^T \approx U_{m \times k} \Sigma_{k \times k} V_{k \times n}^T$$



2.2.3 导数与梯度



一阶导数定义：函数在某一点处切线的斜率

如果一个函数 $f(x)$ 在 x_0 附近有定义，而且存在极限

$$L = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0}.$$

那么 $f(x)$ 在 x_0 处可导且导数 $f'(x_0) = L$.

高阶导数定义：

如果函数的导数函数仍然可导，那么导数函数的导数是二阶导数，二阶导数函数的导数是三阶导数. 一般地记为

$$f^{(n)}(x) = \frac{d}{dx} f^{(n-1)}(x)$$

或者进一步

$$f^{(n)}(x) = \frac{d^n}{dx^n} f(x)$$



- 导数的链式求导法则：

$$y = f(u(x))$$

$$\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx}$$

偏导数



假设二元函数 $f(x, y)$ 在点 (x_0, y_0) 的某个邻域中有定义. 固定 $y = y_0$, 使 x 在 x_0 附近变动, $f(x, y_0)$ 就成为 x 的一元函数. 如果这个函数在 x_0 可导, 即存在极限:

$$\frac{d}{dx} f(x, y_0) = \lim_{\Delta x \rightarrow 0} \frac{f(x_0 + \Delta x, y_0) - f(x_0, y_0)}{\Delta x}.$$

则称这个导数为 $f(x, y)$ 在 (x_0, y_0) 关于变元 x 的偏导数.

记为 $\frac{\partial f(x_0, y_0)}{\partial x}$, 或者 $\left. \frac{\partial f}{\partial x} \right|_{(x_0, y_0)}$. 或者 $f'_x(x_0, y_0)$.

梯度



梯度算子记号 ∇ :

函数的梯度：向量，其偏导数构成的向量：

$$\nabla = \frac{\partial}{\partial x_1} \bar{e}_1 + \frac{\partial}{\partial x_2} \bar{e}_2 + \cdots + \frac{\partial}{\partial x_n} \bar{e}_n$$

对于可微函数 $f(x, y, z)$

$$\nabla = \frac{\partial}{\partial x} \vec{i} + \frac{\partial}{\partial y} \vec{j} + \frac{\partial}{\partial z} \vec{k}$$

$$\nabla f(x, y, z) = (f_x, f_y, f_z)$$

灰度图像--梯度算子离散




- 大小为 $M \times N$ 的灰度数字图像定义:

$$f_{ij} = f(x_i, y_j), \quad i = 1, \dots, M, j = 1, \dots, N$$

- 其梯度定义如下

$$\nabla f = (\nabla_x f, \nabla_y f) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right)$$




一阶向前差分或者向后差分逼近




$$\begin{aligned}\left(\frac{\partial f}{\partial x}\right)_{ij} &= \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x, y) - f(x, y)}{\Delta x} \\ &\approx f(x_{i+1}, y_j) - f(x_i, y_j) \text{ (向前差分逼近)} \\ &= f_{i+1j} - f_{ij}\end{aligned}$$

$$\begin{aligned}\left(\frac{\partial f}{\partial x}\right)_{ij} &= \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x, y) - f(x, y)}{\Delta x} \\ &\approx f(x_i, y_j) - f(x_{i-1}, y_j) \text{ (向后差分逼近)} \\ &= f_{ij} - f_{i-1j}\end{aligned}$$





$$\begin{aligned}\left(\frac{\partial f}{\partial y}\right)_{ij} &= \lim_{\Delta y \rightarrow 0} \frac{f(x, y + \Delta y) - f(x, y)}{\Delta y} \\ &\approx f(x_i, y_{j+1}) - f(x_i, y_j) \text{ (向前差分逼近) } \\ &= f_{ij+1} - f_{ij} \\ &\approx f(x_i, y_j) - f(x_i, y_{j-1}) \text{ (向后差分逼近) } \\ &= f_{ij} - f_{ij-1}\end{aligned}$$





- 大小为**M*N**的灰度数字图像梯度定义:

$$\nabla f = ((\nabla f)_{ij}) = ((\nabla_x f, \nabla_y f)_{ij})$$

$$= [(f_{i+1j} - f_{ij}, f_{ij+1} - f_{ij})]$$

$$i = 2, \dots, M - 1;$$

$$j = 2, \dots, N - 1;$$

- **f**的维度为:**M*N**

$$\nabla_x f \text{的维度: } M * N, \nabla_y f \text{的维度: } M * N$$

$$\nabla f \text{的维度: } M * N * 2$$

- 边界上的梯度:可将边界等值延拓,也可周期延拓



5	4	9	7	3	5	4
3	2	4	6	8	3	2
9	3	1	4	7	9	3
2	7	8	6	4	2	7
5	4	9	7	3	5	4
3	2	4	6	8	3	2

周期延拓

2	4	6	8	3
3	1	4	7	9
7	8	6	4	2
4	9	7	3	5

2	2	4	6	8	3	3
2	2	4	6	8	3	3
3	3	1	4	7	9	9
7	7	8	6	4	2	2
4	4	9	7	3	5	5
4	4	9	7	3	5	5

等值延拓

2.2.4 二阶微分算子



若函数 $f(x, y)$ 二阶可微,其一阶微分为:

$$\mathbf{g} = \nabla f = (f_x, f_y) = (\mathbf{g}_1, \mathbf{g}_2);$$

对应的二阶微分为:

$$\begin{aligned}\nabla \mathbf{g} &= \begin{pmatrix} \mathbf{g}_{1x} & \mathbf{g}_{2x} \\ \mathbf{g}_{1y} & \mathbf{g}_{2y} \end{pmatrix} \\ &= \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}\end{aligned}$$

又称为***Hessian***矩阵

散度算子



- 散度算子: $\text{div}(f)$:

$$\text{div}(f) = \nabla \cdot f \leftarrow \text{注意} f \text{ 为向量, 维度与梯度相同}$$

- 给定函数 $f(x, y) = (f_1, f_2)$

$$\begin{aligned} \text{div}(f) &= \nabla \cdot f \\ &= \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y} \right) \cdot (f_1, f_2) = \frac{\partial f_1}{\partial x} + \frac{\partial f_2}{\partial y} \end{aligned}$$

拉普拉斯算子



- 给定函数 $g(x, y)$
- Laplace算子: $\Delta = \nabla \cdot \nabla :$

$$\Delta g = \nabla \cdot \nabla g$$

$$= \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y} \right) \cdot (g_x, g_y)$$

$$= \operatorname{div}(\nabla g) = g_{xx} + g_{yy}$$

图像 $f(x, y)$ Laplace算子离散：向前差分-向后差分



$$\Delta f = f_{xx} + f_{yy}$$


$$= (f_{i+1j} - f_{ij}) - (f_{ij} - f_{i-1j}) + (f_{ij+1} - f_{ij}) - (f_{ij} - f_{ij-1})$$

$xx \qquad yy$

$$= f_{i+1j} - 4f_{ij} + f_{i-1j} + f_{ij+1} + f_{ij-1}$$

	1	
1	-4	1
	1	

五点差分格式



2.3 范数定义



满足以下条件的函数 $f: \mathbf{R}^n \rightarrow \mathbf{R}$, $\text{dom } f = \mathbf{R}^n$ 称为范数,

- f 是非负的: 对所有的 $x \in \mathbf{R}^n$ 成立 $f(x) \geq 0$,
- f 是正定的: 仅对 $x = 0$ 成立 $f(x) = 0$,
- f 是齐次的: 对所有的 $x \in \mathbf{R}^n$ 和 $t \in \mathbf{R}$ 成立 $f(tx) = |t|f(x)$,
- f 满足三角不等式: 对所有的 $x, y \in \mathbf{R}^n$ 成立 $f(x + y) \leq f(x) + f(y)$ 。

范数是对向量 x 的长度的度量;

$$\|x\|_2 = (x^T x)^{1/2} = (x_1^2 + \cdots + x_n^2)^{1/2}.$$

距离的多种度量




- 欧几里得距离：两点间最短的距离(绿色线)

$$S_{AB} = \sqrt{(x_A - x_B)^2 + (y_A - y_B)^2}$$

- 曼哈顿距离：(红色线)

$$S_{AB} = |x_A - x_B| + |y_A - y_B|$$





- 切比雪夫距离:

$$S_{AB} = \max(|x_A - x_B|, |y_A - y_B|)$$

5	4	3	2	2	2	2	2
5	4	3	2	1	1	1	2
5	4	3	2	1		1	2
5	4	3	2	1	1	1	2
5	4	3	2	2	2	2	2
5	4	3	3	3	3	3	3
5	4	4	4	4	4	4	4
5	5	5	5	5	5	5	5

常用范数



- **L1范数:**

$$\|x\|_1 = |x_1| + \cdots + |x_n|$$

- **L2范数:**

$$\|x\|_2 = (x^T x)^{1/2} = (x_1^2 + \cdots + x_n^2)^{1/2}.$$

- **无穷范数:**

$$\|x\|_\infty = \max\{|x_1|, \cdots, |x_n|\}$$

- **Lp范数:**

$$\|x\|_p = (|x_1|^p + \cdots + |x_n|^p)^{1/p}.$$

- **矩阵F范数:**

$$\|X\|_F = (\text{tr}(X^T X))^{1/2} = \left(\sum_{i=1}^m \sum_{j=1}^n X_{ij}^2 \right)^{1/2}.$$

例题



- 给定3*3灰度图片:

$$u = (u_{ij}), i = 1, 2, 3; j = 1, 2, 3$$

$$(1) \quad y(u) = \|\nabla u\|_2^2$$

$$(2) \quad y(u) = \|\nabla u\|_1$$



$$y = \| \nabla u \|_2^2 = \left(\sqrt{\sum_{ij} (\nabla u_{ij})^2} \right)^2 = \sum_{ij} (\nabla_x u_{ij})^2 + (\nabla_y u_{ij})^2$$

$$= \sum_{ij} (u_{i+1j} - u_{ij})^2 + (u_{ij+1} - u_{ij})^2$$

$$y = \| \nabla u \|_1 = \sum_{ij} | \nabla_x u_{ij} | + | \nabla_y u_{ij} |$$

$$= \sum_{ij} | u_{i+1j} - u_{ij} | + | u_{ij+1} - u_{ij} |$$

$$= \sum_{ij} \sqrt{(\nabla_x u_{ij})^2 + (\nabla_y u_{ij})^2}$$