



智能优化算法

第2章 数学基础知识



2.1 数字图像数据

2.2 导数，梯度，散度

2.3 范数

2.1.3 像素间的关系与距离




- 像素 $p(m,n)$ 的相邻像素

4邻域 $N_4(p)$: $(m+1, n)$, $(m-1, n)$, $(m, n+1)$, $(m, n-1)$

对角邻域 $N_D(p)$: $(m+1, n+1)$, $(m+1, n-1)$, $(m-1, n+1)$, $(m-1, n-1)$

8邻域 $N_8(p)$: $N_4(p) + N_D(p)$



作业1



1. 试用三元组存储以下稀疏矩阵。

$$A_{6 \times 7} = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 & 0 & 0 \\ 3 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 5 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 7 & 4 \end{pmatrix}$$

2. 计算以下矩阵的 SVD 分解。

$$A = \begin{pmatrix} 1 & 0 \\ 2 & 1 \\ 0 & 1 \end{pmatrix}$$



首先计算 $A^T A$ 和 AA^T

$$A^T A = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}$$

$$AA^T = \begin{pmatrix} 1 & 0 \\ 2 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 2 & 0 \\ 2 & 5 & 1 \\ 0 & 1 & 1 \end{pmatrix}$$

计算 $A^T A$ 的特征值和特征向量

$$\lambda_1 = 6; v_1 = \begin{pmatrix} 2/\sqrt{5} \\ 1/\sqrt{5} \end{pmatrix}; \lambda_2 = 1; v_2 = \begin{pmatrix} -1/\sqrt{5} \\ 2/\sqrt{5} \end{pmatrix}$$

计算 AA^T 的特征值和特征向量

$$\lambda_1 = 6; u_1 = \begin{pmatrix} 2/\sqrt{30} \\ 5/\sqrt{30} \\ 1/\sqrt{30} \end{pmatrix}; \lambda_2 = 1; u_2 = \begin{pmatrix} 1/\sqrt{5} \\ 0 \\ -2/\sqrt{5} \end{pmatrix}; \lambda_3 = 0; u_3 = \begin{pmatrix} 2/\sqrt{6} \\ -1/\sqrt{6} \\ 1/\sqrt{6} \end{pmatrix}$$



计算奇异值:

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{6}$$

$$\sigma_2 = \sqrt{\lambda_2} = 1$$

最终得到A的奇异值分解:

$$A = U\Sigma V^T = \begin{pmatrix} 2/\sqrt{30} & 1/\sqrt{5} & 2/\sqrt{6} \\ 5/\sqrt{30} & 0 & 1/\sqrt{6} \\ 1/\sqrt{30} & -2/\sqrt{5} & -1/\sqrt{6} \end{pmatrix} \begin{pmatrix} \sqrt{6} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 2/\sqrt{5} & -1/\sqrt{5} \\ 1/\sqrt{5} & 2/\sqrt{5} \end{pmatrix}$$

2.2.3 导数与梯度



一阶导数定义：函数在某一点处切线的斜率

如果一个函数 $f(x)$ 在 x_0 附近有定义，而且存在极限

$$L = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0}.$$

那么 $f(x)$ 在 x_0 处可导且导数 $f'(x_0) = L$.

高阶导数定义：

如果函数的导数函数仍然可导，那么导数函数的导数是二阶导数，二阶导数函数的导数是三阶导数. 一般地记为

$$f^{(n)}(x) = \frac{d}{dx} f^{(n-1)}(x)$$

或者进一步

$$f^{(n)}(x) = \frac{d^n}{dx^n} f(x)$$

梯度



梯度算子记号 ∇ :

函数的梯度：向量，其偏导数构成的向量：

$$\nabla = \frac{\partial}{\partial x_1} \bar{e}_1 + \frac{\partial}{\partial x_2} \bar{e}_2 + \cdots + \frac{\partial}{\partial x_n} \bar{e}_n$$

对于可微函数 $f(x, y, z)$

$$\nabla = \frac{\partial}{\partial x} \vec{i} + \frac{\partial}{\partial y} \vec{j} + \frac{\partial}{\partial z} \vec{k}$$

$$\nabla f(x, y, z) = (f_x, f_y, f_z)$$

灰度图像--梯度算子离散




- 大小为 $M \times N$ 的灰度数字图像定义:

$$f_{ij} = f(x_i, y_j), \quad i = 1, \dots, M, j = 1, \dots, N$$

- 其梯度定义如下

$$\nabla f = (\nabla_x f, \nabla_y f) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right)$$




一阶向前差分或者向后差分逼近




$$\begin{aligned}\left(\frac{\partial f}{\partial x}\right)_{ij} &= \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x, y) - f(x, y)}{\Delta x} \\ &\approx f(x_{i+1}, y_j) - f(x_i, y_j) \text{ (向前差分逼近)} \\ &= f_{i+1j} - f_{ij}\end{aligned}$$

$$\begin{aligned}\left(\frac{\partial f}{\partial x}\right)_{ij} &= \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x, y) - f(x, y)}{\Delta x} \\ &\approx f(x_i, y_j) - f(x_{i-1}, y_j) \text{ (向后差分逼近)} \\ &= f_{ij} - f_{i-1j}\end{aligned}$$





$$\begin{aligned}\left(\frac{\partial f}{\partial y}\right)_{ij} &= \lim_{\Delta y \rightarrow 0} \frac{f(x, y + \Delta y) - f(x, y)}{\Delta y} \\ &\approx f(x_i, y_{j+1}) - f(x_i, y_j) \text{ (向前差分逼近) } \\ &= f_{ij+1} - f_{ij} \\ &\approx f(x_i, y_j) - f(x_i, y_{j-1}) \text{ (向后差分逼近) } \\ &= f_{ij} - f_{ij-1}\end{aligned}$$





- 大小为**M*N**的灰度数字图像梯度定义:

$$\nabla f = ((\nabla f)_{ij}) = ((\nabla_x f, \nabla_y f)_{ij})$$

$$= [(f_{i+1j} - f_{ij}, f_{ij+1} - f_{ij})]$$

$$i = 2, \dots, M - 1;$$

$$j = 2, \dots, N - 1;$$

- **f**的维度为:**M*N**

$$\nabla_x f \text{的维度: } M * N, \nabla_y f \text{的维度: } M * N$$

$$\nabla f \text{的维度: } M * N * 2$$

- 边界上的梯度:可将边界等值延拓,也可周期延拓



5	4	9	7	3	5	4
3	2	4	6	8	3	2
9	3	1	4	7	9	3
2	7	8	6	4	2	7
5	4	9	7	3	5	4
3	2	4	6	8	3	2

周期延拓

2	4	6	8	3
3	1	4	7	9
7	8	6	4	2
4	9	7	3	5

2	2	4	6	8	3	3
2	2	4	6	8	3	3
3	3	1	4	7	9	9
7	7	8	6	4	2	2
4	4	9	7	3	5	5
4	4	9	7	3	5	5

等值延拓

2.2.4 二阶微分算子



若函数 $f(x, y)$ 二阶可微,其一阶微分为:

$$\mathbf{g} = \nabla f = (f_x, f_y) = (\mathbf{g}_1, \mathbf{g}_2);$$

对应的二阶微分为:

$$\begin{aligned}\nabla \mathbf{g} &= \begin{pmatrix} \mathbf{g}_{1x} & \mathbf{g}_{2x} \\ \mathbf{g}_{1y} & \mathbf{g}_{2y} \end{pmatrix} \\ &= \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}\end{aligned}$$

又称为***Hessian***矩阵

散度算子



- 散度算子: $\text{div}(f)$:

$$\text{div}(f) = \nabla \cdot f \leftarrow \text{注意} f \text{ 为向量, 维度与梯度相同}$$

- 给定函数 $f(x, y) = (f_1, f_2)$

$$\begin{aligned} \text{div}(f) &= \nabla \cdot f \\ &= \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y} \right) \cdot (f_1, f_2) = \frac{\partial f_1}{\partial x} + \frac{\partial f_2}{\partial y} \end{aligned}$$

拉普拉斯算子



- 给定函数 $g(x, y)$
- Laplace算子: $\Delta = \nabla \cdot \nabla :$

$$\Delta g = \nabla \cdot \nabla g$$

$$= \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y} \right) \cdot (g_x, g_y)$$

$$= \operatorname{div}(\nabla g) = g_{xx} + g_{yy}$$

图像 $f(x, y)$ Laplace算子离散：向前差分-向后差分



$$\Delta f = f_{xx} + f_{yy}$$


$$= (f_{i+1j} - f_{ij}) - (f_{ij} - f_{i-1j}) + (f_{ij+1} - f_{ij}) - (f_{ij} - f_{ij-1})$$

$xx \qquad \qquad \qquad yy$

$$= f_{i+1j} - 4f_{ij} + f_{i-1j} + f_{ij+1} + f_{ij-1}$$

	1	
1	-4	1
	1	

五点差分格式



2.3 范数定义



满足以下条件的函数 $f: \mathbf{R}^n \rightarrow \mathbf{R}$, $\text{dom } f = \mathbf{R}^n$ 称为范数,

- f 是非负的: 对所有的 $x \in \mathbf{R}^n$ 成立 $f(x) \geq 0$,
- f 是正定的: 仅对 $x = 0$ 成立 $f(x) = 0$,
- f 是齐次的: 对所有的 $x \in \mathbf{R}^n$ 和 $t \in \mathbf{R}$ 成立 $f(tx) = |t|f(x)$,
- f 满足三角不等式: 对所有的 $x, y \in \mathbf{R}^n$ 成立 $f(x + y) \leq f(x) + f(y)$ 。

范数是对向量 x 的长度的度量;

$$\|x\|_2 = (x^T x)^{1/2} = (x_1^2 + \cdots + x_n^2)^{1/2}.$$

距离的多种度量




- 欧几里得距离：两点间最短的距离(绿色线)

$$S_{AB} = \sqrt{(x_A - x_B)^2 + (y_A - y_B)^2}$$

- 曼哈顿距离：(红色线)

$$S_{AB} = |x_A - x_B| + |y_A - y_B|$$





- 切比雪夫距离:

$$S_{AB} = \max(|x_A - x_B|, |y_A - y_B|)$$

5	4	3	2	2	2	2	2
5	4	3	2	1	1	1	2
5	4	3	2	1		1	2
5	4	3	2	1	1	1	2
5	4	3	2	2	2	2	2
5	4	3	3	3	3	3	3
5	4	4	4	4	4	4	4
5	5	5	5	5	5	5	5

常用范数



- **L1范数:**

$$\|x\|_1 = |x_1| + \cdots + |x_n|$$

- **L2范数:**

$$\|x\|_2 = (x^T x)^{1/2} = (x_1^2 + \cdots + x_n^2)^{1/2}.$$

- **无穷范数:**

$$\|x\|_\infty = \max\{|x_1|, \cdots, |x_n|\}$$

- **Lp范数:**

$$\|x\|_p = (|x_1|^p + \cdots + |x_n|^p)^{1/p}.$$

- **矩阵F范数:**

$$\|X\|_F = (\text{tr}(X^T X))^{1/2} = \left(\sum_{i=1}^m \sum_{j=1}^n X_{ij}^2 \right)^{1/2}.$$

例题



- 给定3*3灰度图片:

$$u = (u_{ij}), i = 1, 2, 3; j = 1, 2, 3$$

$$(1) \quad y(u) = \|\nabla u\|_2^2$$

$$(2) \quad y(u) = \|\nabla u\|_1$$



$$y = \|\nabla u\|_2^2 = \left(\sqrt{\sum_{ij} (\nabla u_{ij})^2} \right)^2 = \sum_{ij} (\nabla_x u_{ij})^2 + (\nabla_y u_{ij})^2$$

$$= \sum_{ij} (u_{i+1j} - u_{ij})^2 + (u_{ij+1} - u_{ij})^2$$

$$y = \|\nabla u\|_1 = \sum_{ij} |\nabla_x u_{ij}| + |\nabla_y u_{ij}|$$

$$= \sum_{ij} |u_{i+1j} - u_{ij}| + |u_{ij+1} - u_{ij}|$$

$$= \sum_{ij} \sqrt{(\nabla_x u_{ij})^2 + (\nabla_y u_{ij})^2}$$