



# 智能优化算法

# 作业1



分别计算以下  $5 \times 5$  图像的Laplace算子，梯度算子，  
边界采用周期边界条件

9	2	3	2	6	9	2
1	1	2	3	2	1	1
2	2	1	2	6	2	2
6	3	0	8	7	6	3
6	1	2	7	8	6	1
9	2	3	2	6	9	2
1	1	2	3	2	1	1

# 常用范数



- **L1范数:**

$$\|x\|_1 = |x_1| + \cdots + |x_n|$$

- **L2范数:**

$$\|x\|_2 = (x^T x)^{1/2} = (x_1^2 + \cdots + x_n^2)^{1/2}.$$

- **无穷范数:**

$$\|x\|_\infty = \max\{|x_1|, \cdots, |x_n|\}$$

- **Lp范数:**

$$\|x\|_p = (|x_1|^p + \cdots + |x_n|^p)^{1/p}.$$

- **矩阵F范数:**

$$\|X\|_F = (\text{tr}(X^T X))^{1/2} = \left( \sum_{i=1}^m \sum_{j=1}^n X_{ij}^2 \right)^{1/2}.$$

## 练习2



- 给定3\*3灰度图片:

$$u = (u_{ij}), i = 1, 2, 3; j = 1, 2, 3$$

$$(1) \quad y(u) = \|\Delta u\|_2^2,$$

$$(2) \quad y(u) = \|\Delta u\|_1,$$

试将以上范数展开



$$\|x\|_1 = \sum_i |x_i| \quad \|x\|_2 = \sqrt{\sum_i x_i^2}$$

$$y(u) = \|\Delta u\|_2^2 = \left( \sqrt{\sum_{ij} (\Delta u_{ij})^2} \right)^2 = \sum_{ij} (\Delta u_{ij})^2$$

$$= \sum_{ij} (-4u_{ij} + u_{ij+1} + u_{ij-1} + u_{i+1j} + u_{i-1j})^2$$

$$y(u) = \|\Delta u\|_1 = \sum_{ij} |\Delta u_{ij}|$$

$$= \sum_{ij} |-4u_{ij} + u_{ij+1} + u_{ij-1} + u_{i+1j} + u_{i-1j}|$$

# 作业3



- 给定3\*3灰度图片:

$$u = (u_{ij}), i = 1, 2, 3; j = 1, 2, 3$$

$$(1) \quad y(u) = \text{div}(\nabla u),$$

$$(2) \quad y(u) = \text{div}\left(\frac{\nabla u}{|\nabla u|}\right),$$

试将以上公式展开，同时证明以下公式成立

$$\langle \nabla u, \nabla u \rangle = -2 \langle \text{div}(\nabla u), u \rangle, \quad \langle \rangle \text{ 表示内积}$$



$$(1) \quad y(u) = \operatorname{div}(\nabla u),$$

$$\nabla u = (u_x, u_y), \operatorname{div}(\nabla u) = (u_{xx} + u_{yy})$$

$$(2) \quad y(u) = \operatorname{div}\left(\frac{\nabla u}{|\nabla u|}\right),$$

$$g(x, y) = \frac{\nabla u}{|\nabla u|} = \frac{(u_x, u_y)}{\sqrt{u_x^2 + u_y^2}} = (g_1, g_2)$$

$$\operatorname{div}(g(x, y)) = g_{1x} + g_{2y}$$

$$g_{1x} = \frac{\partial g_1}{\partial x} = \frac{\partial\left(\frac{u_x}{\sqrt{u_x^2 + u_y^2}}\right)}{\partial x} = \frac{u_{xx} \sqrt{u_x^2 + u_y^2} - u_x \frac{u_x u_{xx} + u_y u_{yx}}{\sqrt{u_x^2 + u_y^2}}}{u_x^2 + u_y^2}$$



$$\langle \nabla \mathbf{u}, \nabla \mathbf{u} \rangle = - \langle \text{div}(\nabla \mathbf{u}), \mathbf{u} \rangle, \quad \langle \rangle \text{ 表示内积}$$

$$\sum_{ij} [(u_{i+1j} - u_{ij})^2 + (u_{ij+1} - u_{ij})^2]$$

$$= - \sum_{ij} (-4u_{ij} + u_{i+1j} + u_{ij+1} + u_{i-1j} + u_{ij-1})u_{ij}$$

$$\begin{aligned} & (-4u_{ij} + u_{i+1j} + u_{ij+1} + u_{i-1j} + u_{ij-1})u_{ij} \\ & + (-4u_{i+1j} + u_{i+2j} + u_{ij+2} + u_{ij} + u_{i+1j-1})u_{i+1j} \\ & + (-4u_{i-1j} + u_{ij} + u_{i-1j+1} + u_{i-2j} + u_{i-1j-1})u_{i-1j} \\ & + (-4u_{ij+1} + u_{i+1j+1} + u_{ij+2} + u_{ij} + u_{i-1j+1})u_{ij+1} \\ & + (-4u_{ij-1} + u_{i+1j-1} + u_{ij} + u_{ij-2} + u_{i-1j-1})u_{ij-1} \\ & + \sum \end{aligned}$$





# 第3章

## 凸优化问题求解算法

## 3.1 线段与直线




设  $x_1 \neq x_2$  为  $\mathbf{R}^n$  空间中的两个点

$x_1$  和  $x_2$  之间的 (闭) 线段 具有以下形式

$$y = \theta x_1 + (1 - \theta)x_2, \quad \text{其中, } 0 \leq \theta \leq 1$$

$\theta \in \mathbf{R}$  为直线



# 仿射函数



函数  $f : \mathbf{R}^n \rightarrow \mathbf{R}^m$  是仿射的,

如果它是一个线性函数和一个常数的和,



$$f(x) = Ax + b$$

# 凸集



集合  $C$  被称为凸集, 如果  $C$  中任意两点间的线段仍然在  $C$  中,  
即对于任意  $x_1, x_2 \in C$  和满足  $0 \leq \theta \leq 1$  的  $\theta$  都有

$$\theta x_1 + (1 - \theta)x_2 \in C.$$



# 凸集例子



10. 欧几里得空间中的球:

$$B(\mathbf{x}_c, r) = \left\{ \mathbf{x} \mid \|\mathbf{x} - \mathbf{x}_c\|_2 \leq r, \mathbf{x}_c \in \mathbf{R}^n, r \in \mathbf{R} \right\}$$

10) 证明: 设  $\mathbf{x}_1, \mathbf{x}_2 \in B$ , 则  $\begin{cases} \|\mathbf{x}_1 - \mathbf{x}_c\|_2 \leq r \\ \|\mathbf{x}_2 - \mathbf{x}_c\|_2 \leq r \end{cases}$

$$\begin{aligned} \|\theta \mathbf{x}_1 + (1-\theta) \mathbf{x}_2 - \mathbf{x}_c\|_2 &= \|\theta \mathbf{x}_1 + (1-\theta) \mathbf{x}_2 - (\theta \mathbf{x}_c + (1-\theta) \mathbf{x}_c)\|_2 \\ &= \|\theta (\mathbf{x}_1 - \mathbf{x}_c) + (1-\theta) (\mathbf{x}_2 - \mathbf{x}_c)\|_2 \\ &\leq \theta \|\mathbf{x}_1 - \mathbf{x}_c\|_2 + (1-\theta) \|\mathbf{x}_2 - \mathbf{x}_c\|_2 \\ &\leq \theta r + (1-\theta) r = r \end{aligned}$$

# 凸函数

函数  $f$  的定义域, 用符号  $\text{dom } f$  描述



**函数  $f$  称为凸函数**, 如果对于其定义域中的任意两点  $x, y$ , 都满足以下条件:


$$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y)$$

其中  $0 \leq \theta \leq 1$

$\text{dom } f$  为凸集

是为了保证  $\theta x + (1-\theta)y$  在定义域内

从几何意义上看, 上述不等式意味着点  $(x, f(x))$  和  $(y, f(y))$  之间的线段, 即从  $x$  到  $y$  的弦, 在函数  $f$  的图像上方



如果等号不成立, 称函数为严格凸的


# 凸函数判定条件(参见P63页证明)



## 一阶条件

假设  $f$  可微, 则函数  $f$  是凸函数的充要条件是  $\text{dom } f$  是凸集且对于任意  $x, y \in \text{dom } f$ , 下式成立

$$f(y) \geq f(x) + \nabla f(x)^T (y - x).$$



# 性质



若  $f$  为凸函数,  $\exists \mathbf{x}_0 \in \text{dom}f$ , 使  $\nabla f(\mathbf{x}_0) = \mathbf{0}$ , 则

$$\text{对 } \forall \mathbf{y} \in \text{dom}f, \quad f(\mathbf{y}) \geq f(\mathbf{x}_0) + \nabla^T f(\mathbf{x}_0)(\mathbf{y} - \mathbf{x}_0) = f(\mathbf{x}_0)$$

即  $f(\mathbf{x}_0)$  是  $f$  的最小值



# 定义



设向量  $\mathbf{x}$  的数量值函数  $f(\mathbf{x})$  二阶可微，则有

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad \nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}, \quad \nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

(Hessian 矩阵)

# 二阶条件




设函数  $f: \mathbf{R}^n \rightarrow \mathbf{R}$  二阶可微，即梯度  $\nabla^2 f$  在  $\text{dom}f$  均存在，则  $f$  为凸函数



若  $\text{dom}f$  为凸集，且对  $\forall \mathbf{x} \in \text{dom}f$ ，有  $\nabla^2 f(\mathbf{x})$  半正定

Note: 对于一维情况，则要求该函数的二阶偏导  $\geq 0$

例：函数  $f(x) = \frac{1}{x^2}$



虽然  $\frac{\partial^2 f(x)}{\partial x^2} = 6x^{-4} > 0$ ，但  $\text{dom}f$  不是凸集，

故不能通过凸函数的二阶条件来判定凸函数

事实上，该函数确实不是凸函数

# 例



$$f(x) = e^{ax}, x \in \mathbb{R}$$

$$f'(x) = e^{ax} a$$

$$f''(x) = e^{ax} a^2 \geq 0$$

故指数函数是凸函数

$$f(x) = \log x, x \in \mathbb{R}_{++}$$

$$f'(x) = \frac{1}{x}$$

$$f''(x) = -\frac{1}{x^2} < 0$$

故对数函数是凹函数

## 3.2 凸优化问题：基本概念



$$\begin{array}{ll}\min & f_o(\mathbf{x}) \\ \text{s.t.} & f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \\ & h_j(\mathbf{x}) = 0 \quad j = 1, \dots, p\end{array}$$

$\mathbf{x}$ : 优化变量 (optimization variable)

$f_o$ : 目标函数/损失函数 (objective function / cost function)

$f_i$ : 不等式约束 (inequality constraint)

$h_j$ : 等式约束 (equality constraint)

域 (Domain)  $D \triangleq \bigcap_{i=0}^m \text{dom} f_i \cap \bigcap_{j=0}^p \text{dom} h_j$

可行解集 (feasible set)

$$X = \left\{ \mathbf{x} \in D \mid \begin{array}{ll} f_i(\mathbf{x}) \leq 0 & i = 1, \dots, m \\ h_j(\mathbf{x}) = 0 & j = 1, \dots, p \end{array} \right\}$$

$\varepsilon$  次优解 ( $\varepsilon$ -suboptimal set)

$$X_\varepsilon = \{ \mathbf{x} \in X \mid f_o(\mathbf{x}) = p^* + \varepsilon \}$$

最优值 (optimal value)

最优解集 (optimal set)


$$p^* = \inf \{ f_o(\mathbf{x}) \mid \mathbf{x} \in X \} \quad X^* = \{ \mathbf{x}^* \in X \mid f_o(\mathbf{x}^*) = p^* \}$$

局部最优值 (local optimal value)

$$\exists R > 0, \quad p_{\text{loc}} = \inf \{ f_o(\mathbf{z}) \mid \|\mathbf{z} - \mathbf{x}\|_2 \leq R, \mathbf{x} \in X, \mathbf{z} \in X \}$$

局部最优解集 (local optimal set)

$$X_{\text{loc}} = \{ \mathbf{x}_{\text{loc}} \in X \mid f_o(\mathbf{x}_{\text{loc}}) = p_{\text{loc}} \}$$



# 凸优化问题



$$\begin{aligned} \min \quad & f_o(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \\ & A_j^T \mathbf{x} = \mathbf{b}_j \quad j = 1, \dots, p \end{aligned}$$

- 1) 目标函数  $f_o(\mathbf{x})$  为凸函数
- 2) 不等式约束  $f_1(\mathbf{x}), \dots, f_m(\mathbf{x})$  为凸函数
- 3) 等式约束  $A_1^T \mathbf{x} = \mathbf{b}_1, \dots, A_p^T \mathbf{x} = \mathbf{b}_p$  为仿射函数

性质：凸优化问题的任意局部最优解也是全局最优解

# 凸优化问题解的最优条件：p132证明



$$\underset{x}{\text{minimize}} \ f_0(x)$$

$$\text{subject to } f_i(x) \leq 0, \ i = 1, \dots, m$$

$$a_j^T x = b_j, \ j = 1, \dots, p$$

$x$  是最优解，当且仅当  $x \in X$  且

$$\nabla f_0(x)^T (y - x) \geq 0, \ \forall y \in X.$$

$$X = \{x \mid f_i(x) \leq 0, \ i = 1, \dots, m, \ h_i(x) = 0, \ i = 1, \dots, p\}.$$

### 3.3 无约束优化问题最优条件



对于无约束优化问题

$$\min_x f_0(x)$$

最优化条件简化为:

$$\nabla f_0(x) = 0.$$



# 例1 线性优化问题



例1:

$$\min_x \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{q}^T \mathbf{x} + r$$

最优性条件为:  $\mathbf{P} \mathbf{x}^* + \mathbf{q} = 0$

如果P为正定矩阵, 存在唯一解  $\mathbf{x}^* = -\mathbf{P}^{-1} \mathbf{q}$

如果P不是正定矩阵, 需讨论解的存在性

## 例2: 最小二乘优化问题

$$\min_x \| \mathbf{A} \mathbf{x} - \mathbf{b} \|_2^2 = \langle \mathbf{A} \mathbf{x} - \mathbf{b}, \mathbf{A} \mathbf{x} - \mathbf{b} \rangle = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} - 2(\mathbf{A}^T \mathbf{b})^T \mathbf{x} + \mathbf{b}^T \mathbf{b}$$

最优性条件为:  $\mathbf{A}^T \mathbf{A} \mathbf{x}^* = \mathbf{A}^T \mathbf{b}$



## 例2：非线性优化问题



$$\min_{\mathbf{x}} \mathbf{f}(\mathbf{x})^T \mathbf{f}(\mathbf{x})$$

$$\mathbf{f}(\mathbf{x}) = \begin{bmatrix} 2(\mathbf{x}_2 - \mathbf{x}_1^2) \\ 1 - \mathbf{x}_1 \end{bmatrix}$$

最优条件：

$$\nabla \mathbf{f}(\mathbf{x}) = \begin{bmatrix} 8(\mathbf{x}_1^3 - \mathbf{x}_1 \mathbf{x}_2) + \mathbf{x}_1 - 1 \\ 4(\mathbf{x}_2 - \mathbf{x}_1^2) \end{bmatrix} = 0$$


无法直接解方程组，  
需要采用迭代方法进行求解



1. 梯度下降法
  2. 最速下降法
  3. 牛顿迭代法
- 参考数值分析

# 梯度下降法(一阶逼近)

问题:  $\min_x f(x)$



1. 给定初始值  $x_0$
2. 一阶泰勒级数  $h(x)$  逼近  $f(x_0)$

$$h(x) = f(x_0 + \Delta x) = f(x_0) + f'(x_0)(x - x_0)$$

3. 求解满足  $h(x)$  最小的值  $x$

$$h(x) = f(x_0 + \Delta x) = f(x_0) - f'(x_0)x_0 + f'(x_0)x$$

4. 当  $x$  与  $f'(x_0)$  方向相反时,  
即成180度时,  $h(x)$  得到最小值

5. 即沿着负梯度方向移动, 每一步的  $f$  值都减小

# 梯度下降算法



输入：初始点  $x_0$ ，固定步长  $\alpha$   
 $k = 1$ ;

**Repeat**

$$x_k = x_{k-1} - \alpha \nabla f(x_{k-1})$$

$$k = k + 1$$

**Until** (满足终止条件)

步长选 $\alpha$ 取问题：

Backtracking line search

## 3.4 只含等式约束的问题



$$\begin{aligned} \min_x & f_0(\mathbf{x}) \\ \text{s.t.} & \quad A\mathbf{x} = \mathbf{b} \end{aligned}$$

最优化条件：

即存在  $\nu \in \mathbf{R}^p$   $\nabla f_0(\mathbf{x}) + A^T \nu = 0$ .

求解方法：将等式约束问题转化为无约束问题  
如：拉格朗日乘子法

## 3.5 Lagrangian dual, 拉格朗日对偶



- 标准的优化问题

$$\begin{aligned} & \underset{x}{\text{minimize}} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && h_j(x) = 0, \quad j = 1, \dots, p \end{aligned}$$

- 拉格朗日对偶的基本思想：  
处理优化问题中的约束条件



- 标准的优化问题

$$\begin{aligned} & \underset{\mathbf{x}}{\text{minimize}} \quad f_0(\mathbf{x}) \\ & \text{subject to} \quad f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & \quad \quad \quad h_j(\mathbf{x}) = 0, \quad j = 1, \dots, p \end{aligned}$$

**拉格朗日函数 (Lagrangian Function)**

$$L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{j=1}^p v_j h_j(\mathbf{x})$$

$$\text{dom} L = \mathbf{D} \times \mathbf{R}^m \times \mathbf{R}^p$$

$\mathbf{x}$ : 原变量 (primal variable)

$\boldsymbol{\lambda}, \mathbf{v}$ : 对偶变量 (dual variable)

$\lambda_i, v_i$ : 拉格朗日乘子 (Lagrange Multiplier)

# 拉格朗日对偶函数



$$g(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu) = \inf_{x \in D} \left( f_o(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x) \right)$$

性质：

假设  $p^*$  为原问题的最优值，  $f_o(x^*) = p^*$

对  $\forall \lambda \geq 0, \nu$ ，对偶函数满足以下不等式：

$$g(\lambda, \nu) \leq p^*$$

即最优值存在下界





证明：设  $\mathbf{x}^*$  是最优解，则  $f_i(\mathbf{x}^*) \leq 0$ ， $h_j(\mathbf{x}^*) = 0$ ，且  $f_o(\mathbf{x}^*) = p^*$

$$L(\mathbf{x}^*, \lambda, \nu) = f_o(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}^*) + \sum_{j=1}^p \nu_j h_j(\mathbf{x}^*) \leq p^*$$

$$g(\lambda, \nu) = \inf_{\mathbf{x} \in D} L(\mathbf{x}, \lambda, \nu) \leq L(\mathbf{x}^*, \lambda, \nu) \leq p^*$$

## 例1:



$$\min_{\mathbf{x}} \mathbf{x}^T \mathbf{x}, \text{ s.t. } A\mathbf{x} = \mathbf{b}$$

**Lagrange**函数为:  $L(\mathbf{x}, \mathbf{v}) = \mathbf{x}^T \mathbf{x} + \mathbf{v}^T (A\mathbf{x} - \mathbf{b})$

最优条件为:  $\nabla L(\mathbf{x}, \mathbf{v}) = 2\mathbf{x} + A^T \mathbf{v} = 0$

$$\Rightarrow \mathbf{x} = -\frac{1}{2} A^T \mathbf{v}$$

对偶函数为:  $g(\mathbf{v}) = \inf_{\mathbf{x}} L(\mathbf{x}, \mathbf{v})$

$$= \left(\frac{1}{2} A^T \mathbf{v}\right)^T \left(\frac{1}{2} A^T \mathbf{v}\right) + \mathbf{v}^T \left(-\frac{1}{2} A A^T \mathbf{v} - \mathbf{b}\right)$$

$$\leq \inf_{\mathbf{x}} \{\mathbf{x}^T \mathbf{x} \mid A\mathbf{x} = \mathbf{b}\}$$

# 拉格朗日对偶问题



- 对偶函数给出原问题最优值的一个下界，即

$$g(\lambda, \nu) \leq p^*$$

- 如何找到最优的下界？

$$\begin{aligned} & \underset{\lambda, \nu}{\text{maximize}} \quad g(\lambda, \nu) \\ & \text{subject to} \quad \lambda \succeq 0 \end{aligned}$$

- 最大的下界问题，即为**Lagrange对偶问题**



### 原问题 (Primal Problem)

$$\begin{aligned} \min \quad & f_o(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \\ & h_j(\mathbf{x}) = 0 \quad j = 1, \dots, p \end{aligned}$$

最优值 (optimal value):  $p^* = \inf \{f_o(\mathbf{x}) \mid \mathbf{x} \in X\}$

### 对偶问题 (Lagrange Dual Problem)

$$\begin{cases} \max & g(\lambda, \mathbf{v}) \\ \text{s.t.} & \lambda \succeq \mathbf{0} \end{cases}$$

最优值 (optimal value):  $d^* = \inf \{g(\lambda, \mathbf{v}) \mid \lambda, \mathbf{v} \in \text{dom} g \text{ \& } \lambda \succeq \mathbf{0}\}$

由对偶函数的性质,  $d^* \leq p^*$

# 弱对偶性、强对偶性、对偶间隙



对偶问题的最优值  $d^*$  与原问题的最优值  $p^*$  满足:  $d^* \leq p^*$

$p^* - d^*$  —— 对偶间隙 (Duality Gap)

$d^* \leq p^*$  —— 弱对偶性 (Weak Duality)

$d^* = p^*$  —— 强对偶性 (Strong Duality)

# 对偶问题例子



$$\min_x c^T x, \quad \text{s.t.} \quad Ax = b, x \geq 0$$

Lagrange函数为: 
$$L(x, \lambda, \nu) = c^T x - \sum_i \lambda_i x_i + \nu^T (Ax - b)$$
$$= -b^T \nu + (c + A^T \nu - \lambda)^T x.$$

对偶函数为: 
$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) = -b^T \nu + \inf_x (c + A^T \nu - \lambda)^T x,$$

$$g(\lambda, \nu) = \begin{cases} -b^T \nu & A^T \nu - \lambda + c = 0 \\ -\infty & \text{其他情况.} \end{cases}$$

可转化为对偶问题:


$$\max_{\lambda, \nu} -b^T \nu,$$

$$\text{s.t.} \quad A^T \nu - \lambda + c = b, \lambda \geq 0$$

## 3.6 鞍点



即不是最大值也不是最小值



**Saddle Point-** Black dot placed on the PES shows a minima along path A-B and a maxima along path C-D. It represents a transition state along path C-D which, in this case, is the reaction coordinate.

# Primal-Dual最优解



若  $(\tilde{\mathbf{x}}, \tilde{\lambda})$  为  $L(\mathbf{x}, \lambda)$  的鞍点  $\Leftrightarrow$

对偶问题满足强对偶性, 且  $(\tilde{\mathbf{x}}, \tilde{\lambda})$  为 Primal-Dual 最优解

$$\inf_{\mathbf{x}} \sup_{\lambda \geq 0} L(\mathbf{x}, \lambda) = \sup_{\lambda \geq 0} \inf_{\mathbf{x}} L(\mathbf{x}, \lambda),$$

$$\text{且} \begin{cases} \tilde{\mathbf{x}} = \arg \inf_{\mathbf{x}} \sup_{\lambda \geq 0} L(\mathbf{x}, \lambda) & \text{primal optimal point} \\ \tilde{\lambda} = \arg \sup_{\lambda \geq 0} \inf_{\mathbf{x}} L(\mathbf{x}, \lambda) & \text{dual optimal point} \end{cases}$$





## 3.7 交替方向乘子方法

**Alternating Direction Method of Multipliers**

简称: **ADMM**

用于求解带等式约束的凸优化问题

解决多个优化变量可分问题

# 拉格朗日乘子法



$$\min_{\mathbf{x}} f(\mathbf{x}), \quad \text{s.t. } A\mathbf{x} = \mathbf{b}$$

Lagrangian函数:  $L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda(A\mathbf{x} - \mathbf{b})$

对偶函数:  $g(\lambda) = \inf_{\mathbf{x}} L(\mathbf{x}, \lambda)$

对偶问题:  $\max_{\lambda} g(\lambda) = \max_{\lambda} \min_{\mathbf{x}} L(\mathbf{x}, \lambda)$

## 求解方法：交替求解



Dual ascent algorithm: 交替求解  $(\mathbf{x}^k, \lambda^k)$

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} L(\mathbf{x}, \lambda^k)$$

$$\lambda^{k+1} = \arg \max_{\lambda} L(\mathbf{x}^{k+1}, \lambda)$$

对偶变量求解：梯度方法

$$\lambda^{k+1} = \arg \max_{\lambda} g(\lambda) = \arg \max_{\lambda} \langle \lambda, A\mathbf{x}^{k+1} - \mathbf{b} \rangle$$

$\lambda$  与  $A\mathbf{x}^{k+1} - \mathbf{b}$  同方向时达到最大

迭代格式为：

$$\lambda^{k+1} = \lambda^k + \alpha^k (A\mathbf{x}^{k+1} - \mathbf{b})$$



交替求解  $(\mathbf{x}^k, \lambda^k)$

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} L(\mathbf{x}, \lambda^k)$$

$$\lambda^{k+1} = \lambda^k + \alpha^k (A\mathbf{x}^{k+1} - \mathbf{b})$$

# 增广拉格朗日函数



为了提高对偶上升方法的**鲁棒性**和放松目标函数的强凸性，引入了增广拉格朗日函数

传统的拉格朗日函数：

$$L(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \langle \boldsymbol{\lambda}, (A\mathbf{x} - \mathbf{b}) \rangle$$

增广拉格朗日函数：

$$L_r(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \langle \boldsymbol{\lambda}, (A\mathbf{x} - \mathbf{b}) \rangle + \frac{r}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2, \quad r > 0$$

**注意区分二者的区别**



$$\min_{\mathbf{x}} f(\mathbf{x}), \quad \text{s.t. } A\mathbf{x} = \mathbf{b}$$

augmented Lagrangian:

增广拉格朗日函数

$$L_r(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \langle \boldsymbol{\lambda}, (A\mathbf{x} - \mathbf{b}) \rangle + \frac{r}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2, \quad r > 0$$

乘子方法:  $\max_{\boldsymbol{\lambda}} \min_{\mathbf{x}} L_r(\mathbf{x}, \boldsymbol{\lambda})$

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} L_r(\mathbf{x}, \boldsymbol{\lambda}^k)$$

$$\boldsymbol{\lambda}^{k+1} = \boldsymbol{\lambda}^k + r(A\mathbf{x}^{k+1} - \mathbf{b})$$

# 交替方向乘子方法



$$\min_x f(\mathbf{x}) + g(\mathbf{z}), \quad \text{s.t.} \quad A\mathbf{x} + B\mathbf{z} = \mathbf{c}$$

augmented Lagrangian

增广拉格朗日函数:

$$L_r(\mathbf{x}, \mathbf{z}, \lambda) = f(\mathbf{x}) + g(\mathbf{z}) + \langle \lambda, (A\mathbf{x} + B\mathbf{z} - \mathbf{c}) \rangle + \frac{r}{2} \|A\mathbf{x} + B\mathbf{z} - \mathbf{c}\|_2^2$$

ADMM算法:  $\max_{\lambda} \min_{\mathbf{x}, \mathbf{z}} L_r(\mathbf{x}, \mathbf{z}; \lambda)$

$$(\mathbf{x}^{k+1}, \mathbf{z}^{k+1}) = \arg \min_{\mathbf{x}, \mathbf{z}} L_r(\mathbf{x}, \mathbf{z}, \lambda^k)$$

$$= \arg \min_{\mathbf{x}, \mathbf{z}} f(\mathbf{x}) + g(\mathbf{z}) + \langle \lambda^k, (A\mathbf{x} + B\mathbf{z} - \mathbf{c}) \rangle + \frac{r}{2} \|A\mathbf{x} + B\mathbf{z} - \mathbf{c}\|_2^2$$

$$\lambda^{k+1} = \arg \max_{\lambda} L_r(\mathbf{x}^{k+1}, \mathbf{z}^{k+1}, \lambda)$$

$$= \arg \max_{\lambda} \langle \lambda, (A\mathbf{x}^{k+1} + B\mathbf{z}^{k+1} - \mathbf{c}) \rangle$$

## 进一步分裂

$$\min_{\mathbf{x}, \mathbf{z}} L_r(\mathbf{x}, \mathbf{z}; \lambda)$$



ADMM算法:

$$\max_{\lambda} \min_{\mathbf{x}, \mathbf{z}} L_r(\mathbf{x}, \mathbf{z}; \lambda)$$

固定 $\mathbf{z}, \lambda$ , 更新 $\mathbf{x}$

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} L_r(\mathbf{x}, \mathbf{z}^k, \lambda^k) = f(\mathbf{x}) + \langle \lambda^k, (A\mathbf{x}) \rangle + \frac{r}{2} \| A\mathbf{x} + B\mathbf{z}^k - \mathbf{c} \|_2^2$$

固定 $\mathbf{x}, \lambda$ , 更新 $\mathbf{z}$

$$\mathbf{z}^{k+1} = \arg \min_{\mathbf{z}} L_r(\mathbf{x}^{k+1}, \mathbf{z}, \lambda^k) = g(\mathbf{z}) + \langle \lambda^k, (B\mathbf{z} - \mathbf{c}) \rangle + \frac{r}{2} \| A\mathbf{x}^{k+1} + B\mathbf{z} - \mathbf{c} \|_2^2$$

固定 $\mathbf{z}, \mathbf{x}$ , 更新 $\lambda$

$$\lambda^{k+1} = \arg \max_{\lambda} L_r(\mathbf{x}^{k+1}, \mathbf{z}^{k+1}, \lambda) = \arg \max_{\lambda} \langle \lambda, (A\mathbf{x}^{k+1} + B\mathbf{z}^{k+1} - \mathbf{c}) \rangle$$



# ADMM算法应用实例



- 求解下列最优化问题

$$\min_{x,y} (x-1)^2 + (y-2)^2$$

$$s.t. \quad 0 \leq x \leq 3,$$

$$1 \leq y \leq 4,$$

$$2x + 3y = 5$$

- 增广拉格朗日函数为:

$$L_{\rho}(x, y, \lambda) = (x-1)^2 + (y-2)^2 + \lambda(2x+3y-5) + \frac{\rho}{2}(2x+3y-5)^2$$





- 求解步骤如下

- 1)  $x^k = y^k = \lambda^k = 0$
- 2)  $x^{k+1} = \arg \min_{0 \leq x \leq 3} L_\rho(x, y^k, \lambda^k),$
- 3)  $y^{k+1} = \arg \min_{1 \leq y \leq 4} L_\rho(x^{k+1}, y, \lambda^k),$
- 4)  $\lambda^{k+1} = \lambda^k + \rho(2x^{k+1} + 3y^{k+1} - 5)$   
*if  $\|s^{k+1}\|_2 \leq \varepsilon^{pri}$  and  $\|\lambda^{k+1}\|_2 \leq \varepsilon^{dual}$ , stop. Else, goto 2)*



- MATLAB仿真结果如下:



## 3.4 ADMM 在图像恢复中的应用



经典稀疏优化问题：lasso模型

$$\min_{\mathbf{x}} \quad \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

L1范数为稀疏范数，具有良好的保边性质

L1范数在0处不可微，

以上无约束问题直接取梯度求解，会出现退化

可通过引入新变量，分离出该不可微项



$$\begin{cases} \min_{\mathbf{x}, \mathbf{y}} & \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{y}\|_1 \\ \text{s.t.} & \mathbf{x} = \mathbf{y} \end{cases}$$

增广拉格朗日函数

$$L_c(\mathbf{x}, \mathbf{y}, \mathbf{v}) = \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{y}\|_1 + \mathbf{v}^T (\mathbf{x} - \mathbf{y}) + \frac{c}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$



①  $\mathbf{x}$  的子问题

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + (\mathbf{v}^k)^T \mathbf{x} + \frac{c}{2} \|\mathbf{x} - \mathbf{y}^k\|_2^2$$

②  $\mathbf{y}$  的子问题

$$\mathbf{y}^{k+1} = \arg \min_{\mathbf{y}} \lambda \|\mathbf{y}\|_1 - (\mathbf{v}^k)^T \mathbf{y} + \frac{c}{2} \|\mathbf{y} - \mathbf{x}^{k+1}\|_2^2$$

③  $\mathbf{v}$  的子问题

$$\mathbf{v}^{k+1} = \mathbf{v}^k + c(\mathbf{x}^{k+1} - \mathbf{y}^{k+1})$$