



智能优化算法



第3章

凸优化问题求解算法

3.2 凸优化问题：基本概念



$$\begin{array}{ll}\min & f_o(\mathbf{x}) \\ \text{s.t.} & f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \\ & h_j(\mathbf{x}) = 0 \quad j = 1, \dots, p\end{array}$$

\mathbf{x} : 优化变量 (optimization variable)

f_o : 目标函数/损失函数 (objective function / cost function)

f_i : 不等式约束 (inequality constraint)

h_j : 等式约束 (equality constraint)

域 (Domain) $D \triangleq \bigcap_{i=1}^m \text{dom} f_i \cap \bigcap_{j=1}^p \text{dom} h_j$

可行解集 (feasible set)

$$X = \left\{ \mathbf{x} \in D \mid \begin{array}{ll} f_i(\mathbf{x}) \leq 0 & i = 1, \dots, m \\ h_j(\mathbf{x}) = 0 & j = 1, \dots, p \end{array} \right\}$$

最优解集 (optimal set)

$$X^* = \{ \mathbf{x}^* \in X \mid f_o(\mathbf{x}^*) = p^* \}$$

最优值 (optimal value)

$$p^* = \inf \{ f_o(\mathbf{x}) \mid \mathbf{x} \in X \}$$

ε 次优解 (ε -suboptimal set)


$$X_\varepsilon = \{ \mathbf{x} \in X \mid f_o(\mathbf{x}) = p^* + \varepsilon \}$$

局部最优值 (local optimal value)

$$\exists R > 0, \quad p_{\text{loc}} = \inf \{ f_o(\mathbf{z}) \mid \|\mathbf{z} - \mathbf{x}\|_2 \leq R, \mathbf{x} \in X, \mathbf{z} \in X \}$$

局部最优解集 (local optimal set)

$$X_{\text{loc}} = \{ \mathbf{x}_{\text{loc}} \in X \mid f_o(\mathbf{x}_{\text{loc}}) = p_{\text{loc}} \}$$



凸优化问题



$$\begin{array}{ll}\min & f_o(\mathbf{x}) \\ \text{s.t.} & f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \\ & A_j^T \mathbf{x} = \mathbf{b}_j \quad j = 1, \dots, p\end{array}$$

- 1) 目标函数 $f_o(\mathbf{x})$ 为凸函数
- 2) 不等式约束 $f_1(\mathbf{x}), \dots, f_m(\mathbf{x})$ 为凸函数
- 3) 等式约束 $A_1^T \mathbf{x} = \mathbf{b}_1, \dots, A_p^T \mathbf{x} = \mathbf{b}_p$ 为仿射函数

性质：凸优化问题的任意局部最优解也是全局最优解

3.3 无约束优化问题最优条件



对于无约束优化问题


$$\min_x f_0(x)$$

最优化条件简化为:

$$\nabla f_0(x) = 0.$$

梯度下降法(一阶逼近)

问题: $\min_x f(x)$



1. 给定初始值 x_0
2. 一阶泰勒级数 $h(x)$ 逼近 $f(x_0)$

$$h(x) = f(x_0 + \Delta x) = f(x_0) + f'(x_0)(x - x_0)$$

3. 求解满足 $h(x)$ 最小的值 x

$$h(x) = f(x_0 + \Delta x) = f(x_0) - f'(x_0)x_0 + f'(x_0)x$$

4. 当 x 与 $f'(x_0)$ 方向相反时,
即成180度时, $h(x)$ 得到最小值

5. 即沿着负梯度方向移动, 每一步的 f 值都减小

梯度下降算法



输入：初始点 x_0 ，固定步长 α
 $k = 1$;

Repeat

$$x_k = x_{k-1} - \alpha \nabla f(x_{k-1})$$

$$k = k + 1$$

Until (满足终止条件)

步长选 α 取问题：

Backtracking line search

多维梯度下降法



$$\min_{\mathbf{x}=(x_1, x_2, \dots, x_d)} f(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_d) = \sum_{i=1}^n f_i(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_d)$$

梯度下降法:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_d} \right]$$

$$= \sum_{i=1}^n \nabla f_i(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_d)$$

$$\mathbf{x}_i^{k+1} = \mathbf{x}_i^k - \eta \sum_{i=1}^n \nabla f_i(\mathbf{x}_1^k, \mathbf{x}_2^k, \dots, \mathbf{x}_d^k)$$

$$i = 1, 2, \dots, d$$

作业1



给定数据集 $\{(\mathbf{x}_i, y_i)\}_{i=1}^m$, 其中 $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{in})$

请写出使用梯度下降法求解以下优化问题的步骤

$$\min_{\mathbf{w}} h(\mathbf{w}) = \sum_{i=1}^m (\mathbf{w}_1 x_{i1} + \mathbf{w}_2 x_{i2} + \dots + \mathbf{w}_n x_{in} - y_i)^2$$

3.4 只含等式约束的问题



$$\begin{aligned} \min_x & f_0(\mathbf{x}) \\ \text{s.t.} & \mathbf{Ax} = \mathbf{b} \end{aligned}$$

最优化条件：

即存在 $\nu \in \mathbf{R}^p$ $\nabla f_0(\mathbf{x}) + \mathbf{A}^T \nu = 0$.

求解方法：将等式约束问题转化为无约束问题
如：拉格朗日乘子法

3.5 Lagrangian dual, 拉格朗日对偶



- 标准的优化问题

$$\begin{aligned} & \underset{x}{\text{minimize}} \quad f_0(x) \\ & \text{subject to} \quad f_i(x) \leq 0, \quad i = 1, \dots, m \\ & \quad \quad \quad h_j(x) = 0, \quad j = 1, \dots, p \end{aligned}$$

- 拉格朗日对偶的基本思想：
处理优化问题中的约束条件



- 标准的优化问题

$$\begin{aligned} & \underset{\mathbf{x}}{\text{minimize}} \quad f_0(\mathbf{x}) \\ & \text{subject to} \quad f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & \quad \quad \quad h_j(\mathbf{x}) = 0, \quad j = 1, \dots, p \end{aligned}$$

拉格朗日函数 (Lagrangian Function)

$$L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{j=1}^p v_j h_j(\mathbf{x})$$

$$\text{dom} L = \mathbf{D} \times \mathbf{R}^m \times \mathbf{R}^p$$

\mathbf{x} : 原变量 (primal variable)

$\boldsymbol{\lambda}, \mathbf{v}$: 对偶变量 (dual variable)

λ_i, v_i : 拉格朗日乘子 (Lagrange Multiplier)

拉格朗日对偶函数



$$g(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu) = \inf_{x \in D} \left(f_o(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x) \right)$$

性质：

假设 p^* 为原问题的最优值， $f_o(x^*) = p^*$

对 $\forall \lambda \geq 0, \nu$ ，对偶函数满足以下不等式：

$$g(\lambda, \nu) \leq p^*$$

即最优值存在下界

拉格朗日对偶问题



- 对偶函数给出原问题最优值的一个下界，即

$$g(\lambda, \nu) \leq p^*$$

- 如何找到最优的下界？

$$\begin{aligned} & \underset{\lambda, \nu}{\text{maximize}} \quad g(\lambda, \nu) \\ & \text{subject to} \quad \lambda \succeq 0 \end{aligned}$$

- 最大的下界问题，即为**Lagrange对偶问题**



原问题 (Primal Problem)

$$\begin{array}{ll}\min & f_o(\mathbf{x}) \\ \text{s.t.} & f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \\ & h_j(\mathbf{x}) = 0 \quad j = 1, \dots, p\end{array}$$

最优值 (optimal value): $p^* = \inf \{f_o(\mathbf{x}) \mid \mathbf{x} \in X\}$

对偶问题 (Lagrange Dual Problem)

$$\begin{cases} \max & g(\lambda, \mathbf{v}) \\ \text{s.t.} & \lambda \succeq \mathbf{0} \end{cases}$$

最优值 (optimal value): $d^* = \inf \{g(\lambda, \mathbf{v}) \mid \lambda, \mathbf{v} \in \text{dom} g \text{ \& } \lambda \succeq \mathbf{0}\}$

由对偶函数的性质, $d^* \leq p^*$

弱对偶性、强对偶性、对偶间隙



对偶问题的最优值 d^* 与原问题的最优值 p^* 满足: $d^* \leq p^*$

$p^* - d^*$ —— 对偶间隙 (Duality Gap)

$d^* \leq p^*$ —— 弱对偶性 (Weak Duality)

$d^* = p^*$ —— 强对偶性 (Strong Duality)

对偶问题例子



$$\min_x c^T x, \quad \text{s.t.} \quad Ax = b, x \geq 0$$

Lagrange函数为:
$$L(x, \lambda, \nu) = c^T x - \sum \lambda_i x_i + \nu^T (Ax - b)$$
$$= -b^T \nu + (c + A^T \nu - \lambda)^T x.$$

对偶函数为:
$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) = -b^T \nu + \inf_x (c + A^T \nu - \lambda)^T x,$$

$$g(\lambda, \nu) = \begin{cases} -b^T \nu & A^T \nu - \lambda + c = 0 \\ -\infty & \text{其他情况.} \end{cases}$$

可转化为对偶问题:

$$\max_{\lambda, \nu} -b^T \nu,$$

$$\text{s.t.} \quad A^T \nu - \lambda + c = b, \lambda \geq 0$$

作业：求以下优化问题的对偶函数，对偶问题



$$\min_{\mathbf{x}} \quad \mathbf{x}^T \mathbf{x}, \text{ s.t. } A\mathbf{x} = \mathbf{b}$$



Lagrange函数为: $L(\mathbf{x}, \mathbf{v}) = \mathbf{x}^T \mathbf{x} + \mathbf{v}^T (A\mathbf{x} - \mathbf{b})$

最优条件为: $\nabla L(\mathbf{x}, \mathbf{v}) = 2\mathbf{x} + A^T \mathbf{v} = 0$

$$\Rightarrow \mathbf{x} = -\frac{1}{2} A^T \mathbf{v}$$

对偶函数为: $g(\mathbf{v}) = \inf_{\mathbf{x}} L(\mathbf{x}, \mathbf{v})$


$$\begin{aligned} &= \left(\frac{1}{2} A^T \mathbf{v}\right)^T \left(\frac{1}{2} A^T \mathbf{v}\right)^T + \mathbf{v}^T \left(-\frac{1}{2} A A^T \mathbf{v} - \mathbf{b}\right) \\ &\leq \inf_{\mathbf{x}} \{\mathbf{x}^T \mathbf{x} \mid A\mathbf{x} = \mathbf{b}\} \end{aligned}$$

对偶问题为: $\max_{\mathbf{v}} g(\mathbf{v}) = \inf_{\mathbf{x}} L(\mathbf{x}, \mathbf{v})$

3.6 鞍点



即不是最大值也不是最小值



Saddle Point- Black dot placed on the PES shows a minima along path A-B and a maxima along path C-D. It represents a transition state along path C-D which, in this case, is the reaction coordinate.

Primal-Dual最优解



若 $(\tilde{\mathbf{x}}, \tilde{\lambda})$ 为 $L(\mathbf{x}, \lambda)$ 的鞍点 \Leftrightarrow

对偶问题满足强对偶性，且 $(\tilde{\mathbf{x}}, \tilde{\lambda})$ 为 Primal-Dual 最优解

$$\inf_{\mathbf{x}} \sup_{\lambda \geq 0} L(\mathbf{x}, \lambda) = \sup_{\lambda \geq 0} \inf_{\mathbf{x}} L(\mathbf{x}, \lambda),$$

$$\text{且} \begin{cases} \tilde{\mathbf{x}} = \arg \inf_{\mathbf{x}} \sup_{\lambda \geq 0} L(\mathbf{x}, \lambda) & \text{primal optimal point} \\ \tilde{\lambda} = \arg \sup_{\lambda \geq 0} \inf_{\mathbf{x}} L(\mathbf{x}, \lambda) & \text{dual optimal point} \end{cases}$$



3.7 交替方向乘子方法

Alternating Direction Method of Multipliers

简称: **ADMM**

用于求解带等式约束的凸优化问题

拉格朗日乘子法



$$\min_{\mathbf{x}} f(\mathbf{x}), \quad \text{s.t. } A\mathbf{x} = \mathbf{b}$$

Lagrangian函数: $L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda(A\mathbf{x} - \mathbf{b})$

对偶函数: $g(\lambda) = \inf_{\mathbf{x}} L(\mathbf{x}, \lambda)$

对偶问题: $\max_{\lambda} g(\lambda) = \max_{\lambda} \min_{\mathbf{x}} L(\mathbf{x}, \lambda)$

求解方法：交替求解



Dual ascent algorithm: 交替求解 $(\mathbf{x}^k, \lambda^k)$

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} L(\mathbf{x}, \lambda^k)$$

$$\lambda^{k+1} = \arg \max_{\lambda} L(\mathbf{x}^{k+1}, \lambda)$$

对偶变量求解：梯度方法

$$\lambda^{k+1} = \arg \max_{\lambda} g(\lambda) = \arg \max_{\lambda} \langle \lambda, A\mathbf{x}^{k+1} - \mathbf{b} \rangle$$

λ 与 $A\mathbf{x}^{k+1} - \mathbf{b}$ 同方向时达到最大

迭代格式为：

$$\lambda^{k+1} = \lambda^k + \alpha^k (A\mathbf{x}^{k+1} - \mathbf{b})$$



交替求解 $(\mathbf{x}^k, \lambda^k)$

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} L(\mathbf{x}, \lambda^k)$$

$$\lambda^{k+1} = \lambda^{k+1} + \alpha^k (A\mathbf{x}^{k+1} - \mathbf{b})$$

增广拉格朗日函数



为了提高对偶上升方法的**鲁棒性**和放松目标函数的强凸性，引入了增广拉格朗日函数

传统的拉格朗日函数：

$$L(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \langle \boldsymbol{\lambda}, (A\mathbf{x} - \mathbf{b}) \rangle$$

增广拉格朗日函数：

$$L_r(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \langle \boldsymbol{\lambda}, (A\mathbf{x} - \mathbf{b}) \rangle + \frac{r}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2, \quad r > 0$$

注意区分二者的区别



$$\min_{\mathbf{x}} f(\mathbf{x}), \quad \text{s.t. } A\mathbf{x} = \mathbf{b}$$

augmented Lagrangian:

增广拉格朗日函数

$$L_r(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \langle \boldsymbol{\lambda}, (A\mathbf{x} - \mathbf{b}) \rangle + \frac{r}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2, \quad r > 0$$

乘子方法: $\max_{\boldsymbol{\lambda}} \min_{\mathbf{x}} L_r(\mathbf{x}, \boldsymbol{\lambda})$

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} L_r(\mathbf{x}, \boldsymbol{\lambda}^k)$$

$$\boldsymbol{\lambda}^{k+1} = \boldsymbol{\lambda}^k + r(A\mathbf{x}^{k+1} - \mathbf{b})$$

多个变量交替方向乘子方法



$$\min_x f(\mathbf{x}) + g(\mathbf{z}), \quad \text{s.t.} \quad \mathbf{Ax} + \mathbf{Bz} = \mathbf{c}$$

augmented Lagrangian

增广拉格朗日函数:

$$L_r(\mathbf{x}, \mathbf{z}, \lambda) = f(\mathbf{x}) + g(\mathbf{z}) + \langle \lambda, (\mathbf{Ax} + \mathbf{Bz} - \mathbf{c}) \rangle + \frac{r}{2} \|\mathbf{Ax} + \mathbf{Bz} - \mathbf{c}\|_2^2$$

ADMM算法: $\max_{\lambda} \min_{\mathbf{x}, \mathbf{z}} L_r(\mathbf{x}, \mathbf{z}; \lambda)$

$$(\mathbf{x}^{k+1}, \mathbf{z}^{k+1}) = \arg \min_{\mathbf{x}, \mathbf{z}} L_r(\mathbf{x}, \mathbf{z}, \lambda^k)$$

$$= \arg \min_{\mathbf{x}, \mathbf{z}} f(\mathbf{x}) + g(\mathbf{z}) + \langle \lambda^k, (\mathbf{Ax} + \mathbf{Bz} - \mathbf{c}) \rangle + \frac{r}{2} \|\mathbf{Ax} + \mathbf{Bz} - \mathbf{c}\|_2^2$$

$$\lambda^{k+1} = \arg \max_{\lambda} L_r(\mathbf{x}^{k+1}, \mathbf{z}^{k+1}, \lambda)$$

$$= \arg \max_{\lambda} \langle \lambda, (\mathbf{Ax}^{k+1} + \mathbf{Bz}^{k+1} - \mathbf{c}) \rangle$$

进一步分裂

$$\min_{\mathbf{x}, \mathbf{z}} L_r(\mathbf{x}, \mathbf{z}; \lambda)$$



ADMM算法:

$$\max_{\lambda} \min_{\mathbf{x}, \mathbf{z}} L_r(\mathbf{x}, \mathbf{z}; \lambda)$$

固定 \mathbf{z}, λ , 更新 \mathbf{x}

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} L_r(\mathbf{x}, \mathbf{z}^k, \lambda^k) = f(\mathbf{x}) + \langle \lambda^k, (A\mathbf{x}) \rangle + \frac{r}{2} \|A\mathbf{x} + B\mathbf{z}^k - \mathbf{c}\|_2^2$$

固定 \mathbf{x}, λ , 更新 \mathbf{z}

$$\mathbf{z}^{k+1} = \arg \min_{\mathbf{z}} L_r(\mathbf{x}^{k+1}, \mathbf{z}, \lambda^k) = g(\mathbf{z}) + \langle \lambda^k, (B\mathbf{z} - \mathbf{c}) \rangle + \frac{r}{2} \|A\mathbf{x}^{k+1} + B\mathbf{z} - \mathbf{c}\|_2^2$$

固定 \mathbf{z}, \mathbf{x} , 更新 λ

$$\lambda^{k+1} = \arg \max_{\lambda} L_r(\mathbf{x}^{k+1}, \mathbf{z}^{k+1}, \lambda) = \arg \max_{\lambda} \langle \lambda, (A\mathbf{x}^{k+1} + B\mathbf{z}^{k+1} - \mathbf{c}) \rangle$$

ADMM算法应用实例



- 求解下列最优化问题

$$\min_{x,y} (x-1)^2 + (y-2)^2$$

$$s.t. \quad 0 \leq x \leq 3,$$

$$1 \leq y \leq 4,$$

$$2x + 3y = 5$$

- 增广拉格朗日函数为：

$$L_{\rho}(x, y, \lambda) = (x-1)^2 + (y-2)^2 + \lambda(2x+3y-5) + \frac{\rho}{2}(2x+3y-5)^2$$





- 求解步骤如下

- 1) $x^k = y^k = \lambda^k = 0$
- 2) $x^{k+1} = \arg \min_{0 \leq x \leq 3} L_\rho(x, y^k, \lambda^k),$
- 3) $y^{k+1} = \arg \min_{1 \leq y \leq 4} L_\rho(x^{k+1}, y, \lambda^k),$
- 4) $\lambda^{k+1} = \lambda^k + \rho(2x^{k+1} + 3y^{k+1} - 5)$
if $\|s^{k+1}\|_2 \leq \varepsilon^{pri}$ and $\|\lambda^{k+1}\|_2 \leq \varepsilon^{dual}$, stop. Else, goto 2)



- MATLAB仿真结果如下:



3.3 ADMM 在图像恢复中的应用



$$\min_x \quad \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_2^2$$

梯度下降法求解

$$\nabla f(x) = A^T (Ax - b) + 2\lambda x$$

$$\begin{aligned} x^{k+1} &= x^k - \alpha \nabla f(x) \\ &= x^k - \alpha [A^T (Ax - b) + \lambda x^k] \end{aligned}$$

3.4 ADMM 在图像恢复中的应用



经典稀疏优化问题：lasso模型

$$\min_{\mathbf{x}} \quad \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

L1范数为稀疏范数，
具有良好的保边性质

梯度下降法求解

$$\nabla f(\mathbf{x}) = \mathbf{A}^T (\mathbf{Ax} - \mathbf{b}) + \lambda \frac{\mathbf{x}}{|\mathbf{x}|}$$

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha \nabla f(\mathbf{x})$$

$$= \mathbf{x}^k - \alpha [\mathbf{A}^T (\mathbf{Ax}^k - \mathbf{b}) + \lambda \frac{\mathbf{x}^k}{|\mathbf{x}^k|}]$$

在0处不可微
求解算法不稳定

可通过引入新变量，分离出该不可微项

如何分离出该不可微项？？？？



$$\min_{\mathbf{x}} \quad \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

$$\begin{cases} \min_{\mathbf{x}, \mathbf{y}} & \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{y}\|_1 \\ \text{s.t.} & \mathbf{x} = \mathbf{y} \end{cases}$$

转换该等式约束优化问题

增广拉格朗日函数

$$L_c(\mathbf{x}, \mathbf{y}, \mathbf{v}) = \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{y}\|_1 + \mathbf{v}^T (\mathbf{x} - \mathbf{y}) + \frac{c}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$



① \mathbf{x} 的子问题

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + (\mathbf{v}^k)^T \mathbf{x} + \frac{c}{2} \|\mathbf{x} - \mathbf{y}^k\|_2^2$$

② \mathbf{y} 的子问题

$$\mathbf{y}^{k+1} = \arg \min_{\mathbf{y}} \lambda \|\mathbf{y}\|_1 - (\mathbf{v}^k)^T \mathbf{y} + \frac{c}{2} \|\mathbf{y} - \mathbf{x}^{k+1}\|_2^2$$

③ \mathbf{v} 的子问题

$$\mathbf{v}^{k+1} = \mathbf{v}^k + c(\mathbf{x}^{k+1} - \mathbf{y}^{k+1})$$

作业2



- 请写出使用**ADMM**算法求解以下优化问题的算法详细步骤

$$\min_{\mathbf{u}} \|\nabla \mathbf{u}\|_1 + \alpha \|\mathbf{u} - \mathbf{u}^0\|_2^2$$