
2021

补充内容：主成分分析

Principal components analysis: **PCA**

□ 为什么降维？

维数灾难：样本的维度的增加而呈指数形式增长。

降维的意义：克服维数灾难，获取本质特征，

节省存储空间，去除无用噪声，

实现数据可视化(大于三维的数据无法可视化)

□ 降维方法分类

① 线性降维方法

主成分分析(PCA), 判别分析(LDA), 多维尺度分析(MDS)

② 非线性降维方法

流形学习，等距特征映射，局部线性嵌入

▣ 高维数据应用背景:

- ▣ **特点:** 维度偏大,

- ▣ **维度灾难:**

随着技术的进步, 数据收集越来越容易, 导致数据规模越来越大、复杂性越来越高, 其维度 (属性) 通常可以达到成百上千维, 甚至更高。

- ▣ **实际情况:** 超过 3 维的数据, 很难直观表示。
面临存储、计算问题。

- ▣ 高维数据中含有很多冗余信息, 因此需要对其降维、简化处理。

数据介绍

表 1

数据维度

学生编号	语文	数学	物理	化学
1	90	140	99	100
2	90	97	88	92
3	90	110	79	83
...

数据：

- 样本数量(1, 2,)
- 维度(特征个数)
- 不同特征起的作用不一样
- 维度过高时，对存储，计算分析带来困难
- 需要去除冗余特征，保留重要的成分。

- PCA:是一种对数据进行分析简化的技术

1901年提出

主成分分析:

- 有效的找出数据中最“主要”的元素和结构,
- 去除噪音和冗余,将原有的复杂数据降维简化
- 揭示隐藏在复杂数据背后的简单结构。

优点是简单,而且无参数限制

- 应用范围极其广泛,从神经科学到计算机图形学都有它的用武之地。

被誉为应用线性代数最有价值的结果之一

表 1

数据维度

学生编号	语文	数学	物理	化学
1	90	140	99	100
2	90	97	88	92
3	90	110	79	83
...

- 表1容易看出，数学、物理、化学，主要成分，其中数学是最重要的成分(区分度大)

表 2

学生编号	数学	物理	化学	语文	历史	英语
1	65	61	72	84	81	79
2	77	77	76	64	70	55
3	67	63	49	65	67	57
4	80	69	75	74	74	63
5	74	70	80	84	82	74
6	78	84	75	62	72	64
7	66	71	67	52	65	57
8	77	71	57	72	86	71
9	83	100	79	41	67	50
...

- 表2则维度大，数据多，分布散乱，无法直接看出其主成分。
- 如果把这些数据换一个空间表示，即换一个观察角度，找出主成分。

1 PCA概述

- PCA:是一种分析、简化数据集的技术
 - 提取、保留数据的主要成分，去掉数据的次要成分。
 - 高维数据降维方法。
- 原理：使用新的一组基(主成分)去重新描述数据空间
新的基要能尽量揭示原有的数据间的关系
- PCA的目标：
找到这样的“基\主元”，最大程度的去除冗余和噪音的干扰

1个样本数据--pca示例

- ▣ **n维样本数据** $x_1 = \begin{pmatrix} x_{11} \\ \vdots \\ x_{1n} \end{pmatrix}$
- ▣ **将其降到k维:** $y_1 = \begin{pmatrix} y_{11} \\ \vdots \\ y_{1k} \end{pmatrix}$
- ▣ **PCA的目标:寻找一组基函数** $P = \begin{pmatrix} \bar{p}_1 \\ \vdots \\ \bar{p}_k \end{pmatrix}$, $\bar{p}_k = (p_{k1}, \dots, p_{kn})$ 为n维向量
- ▣ **满足以下公式:** $y_1 = Px_1$
- ▣ **如何求得 P ?**

m个样本数据--pca示例

□ m个n维数据X $X = (x_1, \dots, x_m)$, 其中 x_i 为n维向量

□ 将其降到k维: $Y = (y_1, \dots, y_m)$, y_m 为k维向量

□ PCA的目标: 寻找一组基函数 $P = \begin{pmatrix} \bar{p}_1 \\ \vdots \\ \bar{p}_k \end{pmatrix}$, $\bar{p}_k = (p_{k1}, \dots, p_{kn})$ 为n维向量

□ 满足以下公式: $Y = PX$

□ 如何求得 P ?

同时满足: ①尽量少损失原始数据信息, ②又去除数据冗余

□ 用什么方法来衡量以上两点??

(方差: 描述数据间分散程度, 也即是满足第一条

协方差: 描述数据间的独立性)

1.2 内积与投影:


- 内积: 二维向量 A, B 内积定义

$$A \cdot B = |A| |B| \cos \theta$$

- 投影: 假设 B 为单位向量, $|B|=1$,

$$A \cdot B = |A| \cos \theta$$

- A 与 B 的**内积值**等于 A 向 B 所在直线投影的矢量长度



1.3 坐标系与向量

- 右图中二维坐标系的基 $\vec{e}_1 = (1,0), \vec{e}_2 = (0,1)$


- 向量 $(3,2)$ 完整表示为:

$$(3,2) = 3\vec{e}_1 + 2\vec{e}_2$$

- 在x轴方向的投影为3,在y轴方向的投影为2

- 上式又可写为

$$(3,2) = \langle (3,2), \vec{e}_1 \rangle \vec{e}_1 + \langle (3,2), \vec{e}_2 \rangle \vec{e}_2$$



因此, 对于 n 维向量 $\vec{a} = (a_1, a_2, \dots, a_n)$,

有
$$\vec{a} = \sum_{i=1}^n \langle \vec{a}, \vec{e}_i \rangle \vec{e}_i$$

注: 任何两个线性无关的二维向量均可作为二维空间的基

不一定正交(正交基的性质较好, 因此通常选取正交)

其它正交基组成的坐标系例子

- 右图中以紫色向量为基构成的新坐标系：

$$\vec{e}'_1 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right), \vec{e}'_2 = \left(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$$

- 试计算向量(3,2)在新坐标系下的坐标：


即:分别计算在新坐标系下x,y轴方向的投影

$$x' = (3,2) \cdot \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) = \frac{5}{\sqrt{2}}$$

$$y' = (3,2) \cdot \left(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) = -\frac{1}{\sqrt{2}}$$

- 因此新坐标为：原坐标在新基下的投影(内积)

$$\begin{pmatrix} x' \\ y' \end{pmatrix} = \begin{pmatrix} \vec{e}'_1 \\ \vec{e}'_2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$




1.4 简单降维例子

- 给定本个样本数据(1,1),(2,2),(3,3)
- 计算其在新坐标系下的坐标: **二维数据降成一维**

$$\vec{e}'_1 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right), \vec{e}'_2 = \left(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$$

$$\begin{pmatrix} \frac{2}{\sqrt{2}} & \frac{4}{\sqrt{2}} & \frac{6}{\sqrt{2}} \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} \vec{e}'_1 \\ \vec{e}'_2 \end{pmatrix} \begin{pmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix}$$

$$= \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix}$$



因此, 选取合适的坐标基, 高维数据在一定的情况下可以实现降维

(即选取 $\vec{e}'_1 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$)

$$\begin{pmatrix} \frac{2}{\sqrt{2}} & \frac{4}{\sqrt{2}} & \frac{6}{\sqrt{2}} \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} \vec{e}'_1 \\ \vec{e}'_2 \end{pmatrix} \begin{pmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix}$$

$$= \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix}$$

问题：对于给定的 n 维数据集： (a_1, \dots, a_M) ,

试图降到 $R < n$ 维空间中？

step 1 : 选取 R 个 n 维线性无关向量 $P = (p_1, \dots, p_R)$;

step 2 : 计算数据在该组向量基下的投影

$$\begin{pmatrix} p_1 \\ p_2 \\ \vdots \\ p_R \end{pmatrix} (a_1 \ a_2 \ \dots \ a_M) = \begin{pmatrix} p_1 a_1 & p_1 a_2 & \dots & p_1 a_M \\ p_2 a_1 & p_2 a_2 & \dots & p_2 a_M \\ \vdots & \vdots & \ddots & \vdots \\ p_R a_1 & p_R a_2 & \dots & p_R a_M \end{pmatrix}$$

关键的问题：

如何选择基 P 才是最优的？

即，如何选取 R 个 n 维线性无关向量，最大程度保留原有的信息

2.1: 数据中心化

- 期望: $E = \frac{1}{N} \sum_i x_i$
- 方差: $\sigma = \frac{1}{N} \sum_i (x_i - E)^2$
- 数据中心化处理:

数据集的每个属性减去其期望

- 注:
1. 特征的量纲和数值得量级都是不一样的,
 2. 通过中心化处理, 可以使得不同的特征具有相同的尺度
 3. 中心化对数据做平移, 不改变数据的形状。
 4. 简化计算

□ 数据中心化处理:

例: 5 个二维数据, 第一维均值为 2, 第二维均值为 3


第一行分别减去均值 2, 第二行分别减去均值 3

$$\begin{pmatrix} 1 & 1 & 2 & 4 & 2 \\ 1 & 3 & 3 & 4 & 4 \end{pmatrix} \longrightarrow \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix}$$

原始数据

中心化后数据

对应方差: $\sigma = \frac{1}{5} \sum_i (x_i - 2)^2$ $\sigma' = \frac{1}{5} \sum_i (x'_i)^2$



例: m 个中心化后样本(2个属性)数据协方差矩阵

$$X = \begin{pmatrix} a_1 & a_2 & \dots & a_m \\ b_1 & b_2 & \dots & b_m \end{pmatrix}$$

$$\frac{1}{m} XX^T = \begin{pmatrix} \frac{\sum_i a_i^2}{m} & \frac{\sum_i a_i b_i}{m} \\ \frac{\sum_i a_i b_i}{m} & \frac{\sum_i b_i^2}{m} \end{pmatrix}$$

- 注意区分样本的维度
- 与矩阵排列方式无关
- 下图为： 5 个 2 维属性(按行排)的样本集：

$$\begin{pmatrix} 1 & 1 & 2 & 4 & 2 \\ 1 & 3 & 3 & 4 & 4 \end{pmatrix}$$

- 下图为： m个n维属性(按列排)的样本集




$$\begin{bmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \dots & \dots & \dots & \dots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{bmatrix}_{m \times n}$$

$$X = \begin{bmatrix} x_{11} - \mu_1 & x_{12} - \mu_2 & \dots & x_{1n} - \mu_n \\ x_{21} - \mu_1 & x_{22} - \mu_2 & \dots & x_{2n} - \mu_n \\ \dots & \dots & \dots & \dots \\ x_{m1} - \mu_1 & x_{m2} - \mu_2 & \dots & x_{mn} - \mu_n \end{bmatrix}_{m \times n}$$

其中 μ_i 是样本矩阵维度 i 的均值： $\mu_i = \frac{1}{m} \sum_{j=1}^m x_{ji}$

2.2 PCA降维

- 对于右图，中心化后的2维简单数据
 - 如何用一维表示这些数据，又尽量保留原始的信息？
- 问题转化
 - 在二维平面中选择一个**方向**，将所有数据投影到直线上
- 如何选择该方向，且保留最多的原始信息？
 - 投影后的投影值尽可能分散



如何选择该方向，且保留最多的原始信息？



投影后的投影值尽可能分散

向x轴投影：

最左边的两个点会重叠，中间的两个点也会重叠，四个不相同的点投影后只剩两个，这是一种严重的信息丢失

同理向y轴投影，也会出现信息丢失

向通过第一象限和第三象限的斜线投影，数据较分散。



2.3 方差：描述投影后投影值的分散程度

□ 方差：

$$\sigma^2 = \sum_i (x_i - \mu)^2 / n$$

□ PCA原理：

投影后投影值尽可能分散，
而这种分散程度，可以用**方差**来描述

□ **二维降一维**，问题转化：

寻找一个一维基，
所有数据变换为这个基上的坐标表示后，**方差值最大**。

□ **高维降低维时**，需要添加其它的约束条件
协方差 及协方差矩阵

2.4 协方差矩阵：衡量特征间的独立性

- 样本特征间的协方差： 衡量任意 2 个特征间的互相独立性

$$\text{cov}(x_i, x_j) = \frac{\sum_k (x_{ik} - \mu_i)(x_{jk} - \mu_j)}{n},$$

μ_i : 第*i*个属性的均值

- 样本协方差矩阵： 衡量n个特征间的互相独立性

$$C = [c_{ij}]_{n \times n} = [\text{cov}(x_i, x_j)]_{n \times n}$$

注： 如果某2个维度间存在相关性，

说明从一个维度的值可以推测出另一个维度的值。

则该维度中有一个是多余的，可以把其中一个维度舍去。

▣ 三维降二维，问题转化：

①找第一个方向使投影后方差最大，尽量分散，不重叠

②找第二个方向(基)时，与第一个方向没有相关性

“样本属性投影后尽可能互相独立”

即，属性**投影后的协方差为 0**

③**为了让协方差为0**

需要使第二个方向与第一个方向正交

▣ 同理高维降低维.....

2.5 PCA优化目标

- 将N维向量降为K维(K小于N)的**优化目标**:

选择K个单位正交基, 使原始数据投影到这组基后:

样本属性间协方差为 0 , 方差尽可能大。

问题分析:

例: m 个中心化后样本(2个属性)数据的协方差矩阵

$$X = \begin{pmatrix} a_1 & a_2 & \dots & a_m \\ b_1 & b_2 & & b_m \end{pmatrix}$$

$$\frac{1}{m}XX^T = \begin{pmatrix} \frac{\sum_i a_i^2}{m} & \frac{\sum_i a_i b_i}{m} \\ \frac{\sum_i a_i b_i}{m} & \frac{\sum_i b_i^2}{m} \end{pmatrix}$$

$$C = \frac{XX^T}{m} : \text{样本属性的协方差矩阵}$$

主对角线为方差,

非主对角线为协方差

$$C = \frac{XX^T}{m} : \text{样本属性的协方差矩阵}$$

主对角线为方差，
非主对角线为协方差

□ 假设K个正交基构成的矩阵为 $P: K \times n$

记投影后样本为 $Y = PX: K \times m$

记Y的协方差矩阵为 **D(依旧满足中心化): 对角矩阵**

(满足协方差为0, 方差尽可能大)

$$D = \frac{YY^T}{m} = \frac{PXX^T P^T}{m} = PCP^T, \text{ 根据特征值分解公式}$$

因此, P是能让原始协方差矩阵C对角化的一组基。

- **P是能让原始协方差矩阵C对角化的一组基，且满足方差最大，协方差为 0**

$$D = \frac{YY^T}{m} = \frac{PXX^TP^T}{m} = PCP^T, \text{ 根据特征值分解公式}$$

- 根据矩阵的迹的定义 $\text{tr}(A)$: 矩阵对角线元素之和

$$\text{tr}(A) = \sum_i a_{ii}$$

- PCA: 求正交基，满足协方差矩阵的迹最大化

$$\max_P \text{tr}(PCP'), \quad \text{s.t. } PP' = I$$

$$\max_P \text{tr}(PCP'), \quad \text{s.t. } PP' = I$$

- 根据拉格朗日乘子法：求得拉格朗日函数

$$L = \text{tr}(PCP') + \lambda(PP' - I)$$

- 对拉格朗日函数关于 P 求偏导置 0

$$\frac{\partial L}{\partial P} = CP' + \lambda P' = 0$$

满足特征向量的关系式

- 因此**由C矩阵(协方差矩阵)的特征向量构成的矩阵，即是要求的变换矩阵 **P**

PCA优化目标分析:

①寻找矩阵P,

满足 PCP^T 是对角矩阵, 且对角线元素从大到小依次排列;

②P的前K行组成的矩阵乘以X就使得X从N维降到了K维;

且满足(方差最大, 协方差为 0) 优化条件。

协方差矩阵C是实对称矩阵, 有一系列非常好的性质:

- 1) 实对称矩阵不同特征值对应的特征向量必然正交。
- 2) 存在正交矩阵 P, 使得 $P^{-1}CP = \Lambda$, 且 Λ 为对角矩阵, 主对角线元素为 C 的特征值, P 是 C 的特征向量构成的矩阵

2.6 PCA 求解目标

▣ PCA问题：对样本进行降维，去掉冗余特征，保留主要成分

① 降维后同一维度的方差最大

② 不同维度之间的相关性为0

▣ 转化后求解目标：

①求投影矩阵 P ：

样本属性的协方差矩阵 C 的前 K 个最大的特征值对应的特征向量

②使用 P 对样本 X 进行降维

□ PCA算法流程

设有m个n维数据X

$$X = \{x_1, x_2, \dots, x_m\}$$

1. 将原始数据按列组成n行m列矩阵

2. 将X的每一行进行零均值化，即减去每一行的均值

$$\bar{X} = \begin{Bmatrix} x_{11} - \mu_1 & x_{21} - \mu_1 & x_{31} - \mu_1 & \cdots & x_{m1} - \mu_1 \\ x_{12} - \mu_2 & x_{22} - \mu_2 & x_{32} - \mu_2 & \cdots & x_{m2} - \mu_2 \\ x_{13} - \mu_3 & x_{23} - \mu_3 & x_{33} - \mu_3 & \cdots & x_{m3} - \mu_3 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{1n} - \mu_n & x_{2n} - \mu_n & x_{3n} - \mu_n & \cdots & x_{mn} - \mu_n \end{Bmatrix}$$

3. 计算协方差矩阵

$$C = \frac{\bar{X} * \bar{X}^T}{m}$$

4. 求出协方差矩阵的前K个最大的特征值及对应的特征向量

5. 将特征向量组成矩阵P

6. $Y = PX$ 即为降维到k维后的数据

2.7 PCA例子

对右边数据中心化处理

$$\begin{pmatrix} 1 & 1 & 2 & 4 & 2 \\ 1 & 3 & 3 & 4 & 4 \end{pmatrix} \Rightarrow \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix}$$

计算其协方差矩阵 C

$$C = \frac{1}{5} \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} -1 & -2 \\ -1 & 0 \\ 0 & 0 \\ 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} \end{pmatrix}$$

求 C 的特征值与特征向量(单位化)


$$\lambda_1 = 2, \lambda_2 = 2/5 \quad \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

投影矩阵 P

$$P = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

对数据进行降维

$$Y = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} = \begin{pmatrix} -3/\sqrt{2} & -1/\sqrt{2} & 0 & 3/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$



- PCA求协方差矩阵C的最大的 K 个特征值对应的特征向量
- 协方差矩阵C，样本属性间的协方差

$$C = \frac{XX^T}{m}$$

- 当维度比较大时，直接计算协方差矩阵，计算量存储都很大
- SVD中的U,V分别为矩阵 AA^T 与 $A^T A$ 的特征向量
- **计算协方差矩阵 C 的特征向量，等价于求样本矩阵 X 的奇异矩阵**
- **直接省掉了计算协方差矩阵的计算量和存储**

2.8 最小二乘误差解释 PCA

- 普通二维向量的表示方式:

$$\begin{aligned} a = \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} &= \langle a, e_1 \rangle e_1 + \langle a, e_2 \rangle e_2 \\ &= (a^T e_1) e_1 + (a^T e_2) e_2 \\ &= \langle a, e_1 \rangle \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \langle a, e_2 \rangle \begin{pmatrix} 0 \\ 1 \end{pmatrix} \end{aligned}$$

- n 维向量 x 可表示为

$$x = \sum_{i=1, n} \langle w_i, x \rangle w_i$$

- PCA问题：给定n维样本 x_i 求一组基函数

$$W = \{w_1, \dots, w_K\} (w_i \in R^n, n\text{维基向量, 互相正交})$$

- x_i 在该K个基函数的表示为

$$\hat{x}_i = \sum_{k=1, K} \langle w_k, x_i \rangle w_k = W W^T x_i$$

- 最小二乘误差 PCA, 可视为求解以下优化问题:

$$\min_W \|x_i - \hat{x}_i\|^2, \text{ s.t. } W^T W = I$$

- 即等价于:

$$\min_W \left\| x_i - \sum_k \langle x_i, w_k \rangle w_k \right\|_2^2, \quad s.t. \quad W^T W = I$$

- 对目标函数进行简化

$$\begin{aligned} \left\| x_i - W W^T x_i \right\|_2^2 &= -2x_i^T W W^T x_i + x_i^T W W^T W W^T x_i \\ &= -x_i^T W W^T x_i \\ &= -\left\| W^T x_i \right\|_2^2 \end{aligned}$$

- 原问题转化为

$$\max_W \left\| W^T x_i \right\|_2^2, \quad s.t. \quad W^T W = I$$

- 将 x_i 推广到 m 个样本集 X , 则最小二乘误差下的 PCA :

$$\min_W \|X - \hat{X}\|^2 = \max_W \text{tr}(W^T X X^T W), \quad \text{s.t. } W^T W = I$$

- W 即为所求的投影矩阵 P :

即由协方差矩阵的最大的 K 个特征向量组成


- 最新研究方向: $L1$ 范数下的 PCA 问题:

$$\max_W \|W^T X\|, \quad \text{s.t. } W^T W = I$$

- 请将以下 5 个 4 维样本降至 3 维

0	4.9	3.0	1.4	0.2
1	4.7	3.2	1.3	0.2
2	4.6	3.1	1.5	0.2
3	5.0	3.6	1.4	0.2
4	5.4	3.9	1.7	0.4

- 请使用PCA 算法将以下三个3维数据降至2维



□ 请使用PCA 算法将以下三个3维数据降至2维

```
%% Swiss roll
%% Create the data
N = 10000;
% Noise term weighting (for Swiss roll and S-curve)
noise = 0.05;
% Size of points (for plotting)
sz = 10;
t = 3*pi/2 * (1 + 2*rand(N,1));
h = 11 * rand(N,1);
X = [t.*cos(t), h, t.*sin(t)] + noise*randn(N,3);

figure('Position', [200,500,1000,1000], 'WindowStyle', 'docked');
subplot(1,3,1);
scatter3(X(:,1),X(:,2),X(:,3),sz,t,'fill');
axis('equal','tight');
title('Swiss roll');
```

```
t = 3 * pi * (rand(N,1) - 0.5);
x = sin(t);
y = 2.0 * rand(N,1);
z = sign(t) .* (cos(t) - 1);
X = [x,y,z] + noise*randn(N,3);

subplot(1,3,2);
scatter3(X(:,1),X(:,2),X(:,3),sz,t,'fill');
axis('equal','tight');
title('S-curve');
```

```
p = rand(N,1) * (2 * pi - 0.55);
t = rand(N,1) * pi; % Sever the poles from the sphere.
indices = ((t < (pi - (pi / 8))) & (t > ((pi / 8))));
c = p(indices);
X = [sin(t(indices)) .* cos(p(indices)), sin(t(indices)) .* sin(p(indices)), cos(t(indices))];

subplot(1,3,3);
scatter3(X(:,1),X(:,2),X(:,3),sz,c,'fill');
axis('equal','tight');
title('Severed sphere');
```